

《人工智能引论》章后习题

第一章 绪论

1. 为保证形式化系统的有效性，下面哪个选项不是形式化系统需要具有的性质（ ）

- A. 完备性
- B. 可靠性
- C. 一致性
- D. 可判定性

该题选项 B

2. Deepmind 研制的 AlphaGo 算法没有使用哪个人工智能方法（ ）

- A. 强化学习
- B. 深度学习
- C. 蒙特卡洛树搜索
- D. 逻辑推理

该题选项 D

3. 图灵奖获得者 Judea Pearl 将推理按照由易到难程度分成三个层次（ ）

- A. 干预、关联、反事实
- B. 关联、干预、反事实
- C. 反事实、干预、关联
- D. 关系、干预、反事实

该题选项 B

4. 以下哪种搜索方法属于启发式搜索（ ）

- A. 广度优先搜索
- B. 蒙特卡洛树搜索
- C. 深度优先搜索
- D. A*搜索

该题选项 D

5. 以下哪一种算法不属于监督学习算法（ ）

- A. 隐马尔科夫链
- B. 支持向量机
- C. 聚类
- D. 决策树

该题选项 C

6. 以下哪种学习方法的学习目标是学习同一类数据的分布模式（ ）

- A. 监督学习
- B. 无监督学习
- C. 强化学习
- D. 博弈对抗

该题选项 B

7. 以机器为载体来模拟人类智能的某一方面，可通过以符号主义为核心的逻辑推理、以问题求解为核心的探寻搜索、以数据驱动为核心的机器学习、以行为主义为核心的强化学习、以博弈对抗为核心的决策智能等方法来实现。请比较上述人工智能不同方法的优劣。

参考答案：

逻辑推理方法解释性强、但难以拓展；搜索方法从已有答案中进行查找、但桎于机械式匹配；数据驱动模型擅于预测识别、但是其过程难以理解；强化学习手段能对未知空间进行探索、但其依赖于策略学习；博弈对抗在完全信息条件下表现优良、但难以找到非完全信息条件下的通用框架。

8. 请参考图 1.2.1，画出使用图灵机模型计算 $(5+2)*3$ 的过程示意图。

参考答案：

计算过程合理即可

9. 推理方法在生活中无处不在，请你针对归纳推理、演绎推理和因果推理分别举出实际例子。

参考答案：

言之有理即可

10. 监督学习和强化学习在做出预测后，都需要某种“反馈信息”来提升学习性能。请描述两种学习方法中利用“反馈信息”的不同。

参考答案：

强化学习有环境、智能体、状态、奖励、决策等诸多要素，涉及序列决策过程，智能体前面作出的决策会影响智能体当前的状态，从而影响“未来”的决策过程。而监督学习中，对每一个样本输入做出的决策不会影响到“未来”的决策。

监督学习的每次决策后得到的反馈是“最终反馈”，它包含了最佳决策的信息。而强化学习每次决策后得到的反馈只是当前步的反馈。

11. 目前人工智能在大多数任务上所体现性能与人类智能存在不小差距。机器智能和人类智能之间进行相互协同所形成的人机混合增强是推动人工智能发展的务实之路。“假舆马者，非利足也，而致千里；假舟楫者，非能水也，而绝江河”，人类可以通过外界帮助来提升能力。请列举若干人机混合增强的例子。

参考答案：

言之有理即可

第二章 知识表达与推理

1. p 和 q 均是原子命题,“如果 p 那么 q ”是由 p 和 q 组合得到的复合命题。下面对

“如果 p 那么 q ”这一复合命题描述不正确的是 ()

A. “如果 p 那么 q ”定义的是一种蕴涵关系 (即充分条件)

B. “如果 p 那么 q ”意味着命题 q 包含着命题 p , 即 p 是 q 的子集

C. 无法用真值表来判断“如果 p 那么 q ”的真假

D. 当 p 不成立时,“如果 p 那么 q ”恒为真

该题选项 C

2. 下面哪个逻辑等价关系是不成立的 ()

A. $\forall x \neg P(x) \equiv \neg \exists x P(x)$

B. $\neg \forall x P(x) \equiv \exists x \neg P(x)$

C. $\forall x P(x) \equiv \neg \exists x \neg P(x)$

D. $\exists x P(x) \equiv \neg \forall x P(x)$

该题选项 D

3. 下面对一阶归纳推理 (FOIL) 中信息增益值(information gain)阐释不正确的是 ()

A. 信息增益值用来判断向推理规则中所加入前提约束谓词的质量

B. 在算法结束前, 每次向推理规则中加入一个前提约束谓词, 该前提约束谓词得到的新推理规则具有最大的信息增益值。

C. 在计算信息增益值过程中, 需要利用所得到的新推理规则和旧推理规则分别涵盖的正例和反例数目

D. 信息增益值大小与背景知识样例数目直接相关

该题选项 D

4. 下面哪个描述的问题不属于因果分析的内容 ()

A. 如果商品价格涨价一倍, 预测销售量(sales)的变化

B. 如果广告投入增长一倍, 预测销售量(sales)的变化

C. 如果放弃吸烟, 预测癌症(cancer)的概率

D. 购买了一种商品的顾客是否会购买另外一种商品

该题选项 D

5. 判断下列句子是否为命题。

- a) $x > 2$ 。
- b) 今天的天气真好啊!
- c) 浙江大学始创于 1897 年。

解 a) 不是命题, 因为无法判断真假;
b) 不是命题, 因为不是陈述句;
c) 是命题, 其真值为真。

6. 应用归结法证明以下命题集是不可满足的。

- a) $\alpha \vee \beta$;
- b) $\beta \rightarrow \gamma$;
- c) $\neg\alpha \wedge \neg\gamma$;

解 应用归结法:

- (1) $\alpha \vee \beta$ (已知);
- (2) $\neg\beta \vee \gamma$ (b 进行蕴涵消除);
- (3) $\alpha \vee \gamma$ (由 1 和 2);
- (4) $\neg(\alpha \vee \gamma)$ (c 使用 De Morgan 定律)
- (5) 3 和 4 矛盾, 因此原命题集是不可满足的。

7. 使用全称量词或存在量词描述下列事实。

- a) 不是所有的篮球运动员的身高都超过 1 米 8
- b) 所有实数的平方都大于等于零

解 a) $\neg(\forall x)(Basketball_player(x) \rightarrow Higher_than(x, 1.8m))$ 。其中,
 $Basketball_player(x)$ 表示 x 是篮球运动员, $Higher_than(x, 1.8m)$ 表示
 x 的身高超过 1 米 8。

b) $(\forall x)(Real(x) \rightarrow More_than(Square(x), 0))$ 。其中, $Real(x)$ 表示 x 是实数, $Square(x)$ 表示 x 的平方, $More_than(Square(x), 0)$ 表示 x 的平方大于等于 0。

8. 已知 $(\forall x)(F(x) \rightarrow (G(x) \vee H(x)))$, $\neg((\forall x)(F(x) \rightarrow G(x)))$, 试证明 $(\exists x)(F(x) \wedge H(x))$ 。

解 (1) $\neg(\forall x)(F(x) \rightarrow G(x))$

(2) $(\exists x)\neg(F(x) \rightarrow G(x))$

(3) $(\exists x)\neg(\neg F(x) \vee G(x))$

(4) $(\exists x)(F(x) \wedge \neg G(x))$

(5) $F(a) \wedge \neg G(a)$ (存在量词消去)

(6) $F(a)$ (由 5 知)

(7) $\neg G(a)$ (由 5 知)

(8) $(\forall x)(F(x) \rightarrow G(x) \vee H(x))$

(9) $F(a) \rightarrow G(a) \vee H(a)$ (全称量词消去)

(10) $G(a) \vee H(a)$ (6 和 9 的假言推理)

(11) $H(a)$ (由 7 和 10 知)

(12) $F(a) \wedge H(a)$ (由 6 和 11 知)

(13) $(\exists x)(F(x) \wedge H(x))$ (存在量词引入)

9. 如果将图 2.3.1 中 James 和 Ann 之间的 *Mother* 关系去掉，同时添加 David 和 Ann 之间的 *Father* 关系，则得到了下图。试运用 FOIL 算法推出 James 和 Ann 的 *Mother* 关系。




图 1 家庭关系图

解 在给定目标谓词 *Mother*(*x*, *y*) 之后，可如下表来构造背景知识样例和训练样例。

背景知识 样例集合	<i>Sibling</i> (Ann, Mike)	目标谓词 训练样例 集合	<i>Mother</i> (James, Mike)
	<i>Couple</i> (James, David)		$\neg$ <i>Mother</i> (James, David)
	<i>Father</i> (David, Ann)		$\neg$ <i>Mother</i> (David, Ann)
	<i>Father</i> (David, Mike)		$\neg$ <i>Mother</i> (David, Mike)
			$\neg$ <i>Mother</i> (Ann, Mike)

按照表 2.3.1 中 FOIL 算法所列步骤依次将每个候选前提约束谓词加入到推理规则中，并计算所得新的推理规则对应的 FOIL 增益值。基于计算所得 FOIL 增益值来确定最佳前提约束谓词。下表给出了添加前提约束谓词后信息增益的计算结果。

推理规则		推理规则涵盖的正例和反例数		FOIL 信息增益
目标谓词	前提约束谓词	正例	反例	信息增益值
<i>Mother</i> (<i>x</i> , <i>y</i>) ←	空集	$m_+ = 1$	$m_- = 4$	/
<i>Mother</i> (<i>x</i> , <i>y</i>) ←	<i>Father</i> (<i>x</i> , <i>y</i>)	$\hat{m}_+ = 0$	$\hat{m}_- = 2$	NA
	<i>Father</i> (<i>x</i> , <i>z</i>)	$\hat{m}_+ = 0$	$\hat{m}_- = 2$	NA

	<i>Father</i> (y, x)	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	<i>Father</i> (y, z)	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA
	<i>Father</i> (z, x)	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA
	<i>Father</i> (z, y)	$\hat{m}_+ = 1$	$\hat{m}_- = 3$	0.32
	<i>Sibling</i> (x, y)	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA
	<i>Sibling</i> (x, z)	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA
	<i>Sibling</i> (y, x)	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	<i>Sibling</i> (y, z)	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA
	<i>Sibling</i> (z, x)	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	<i>Sibling</i> (z, y)	$\hat{m}_+ = 1$	$\hat{m}_- = 2$	0.74
	<i>Couple</i> (x, y)	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA
	<i>Couple</i>(x, z)	$\hat{m}_+ = 1$	$\hat{m}_- = 1$	1.32
	<i>Couple</i> (y, x)	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	<i>Couple</i> (y, z)	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	<i>Couple</i> (z, x)	$\hat{m}_+ = 0$	$\hat{m}_- = 2$	NA
	<i>Couple</i> (z, y)	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA

由于*Couple*(x, z)的 FOIL 增益值最大，因此选择*Couple*(x, z)加入推理规则，得到*Couple*(x, z) $\rightarrow$ *Mother*(x, y)这一新的推理规则，并将训练样例集合中与该推理规则不符样例去掉。此时，背景知识样例和训练样本如下表：

背景知识 样例集合	<i>Sibling</i> (Ann, Mike) <i>Couple</i> (James, David) <i>Father</i> (David, Ann)	目标谓词 训练样例 集合	<i>Mother</i> (James, Mike) $\neg$ <i>Mother</i> (James, David)
--------------	--	--------------------	--

	<i>Father</i> (David, Mike)		
--	-----------------------------	--	--

接着，再用相同方法继续将其他谓词逐一作为前提约束谓词加入推理规则进行考察，用 FOIL 增益值来判断选取最优推理规则。

推理规则		推理规则涵盖的 正例和反例数		FOIL 信息增益值
现有规则	拟加入前提 约束谓词	正例	反例	信息增益值
$Mother(x, y) \leftarrow Couple(x, z)$		$m_+ = 1$	$m_- = 1$	/
$Mother(x, y) \leftarrow Couple(x, z)$	$\wedge Father(x, y)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	$\wedge Father(x, z)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	$\wedge Father(y, x)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	$\wedge Father(y, z)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	$\wedge Father(z, x)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	$\wedge \mathbf{Father}(z, y)$	$\hat{\mathbf{m}}_+ = \mathbf{1}$	$\hat{\mathbf{m}}_- = \mathbf{0}$	1
	$\wedge Sibling(x, y)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	$\wedge Sibling(x, z)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
	$\wedge Sibling(y, x)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA

$\wedge \text{Sibling}(y, z)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
$\wedge \text{Sibling}(z, x)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
$\wedge \text{Sibling}(z, y)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
$\wedge \text{Couple}(x, y)$	$\hat{m}_+ = 0$	$\hat{m}_- = 1$	NA
$\wedge \text{Couple}(x, z)$	$\hat{m}_+ = 1$	$\hat{m}_- = 1$	0
$\wedge \text{Couple}(y, x)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
$\wedge \text{Couple}(y, z)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
$\wedge \text{Couple}(z, x)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA
$\wedge \text{Couple}(z, y)$	$\hat{m}_+ = 0$	$\hat{m}_- = 0$	NA

当 $Father(z, y)$ 作为前提约束谓词加入到推理规则后 $FOIL_Gain$ 值最大，因此将 $Father(z, y)$ 加入，得到新的推理规则 $Father(z, y) \wedge Couple(x, z) \rightarrow Mother(x, y)$ 。当 $x = \text{James}$ 、 $y = \text{Mike}$ 和 $z = \text{David}$ 时，该推理规则覆盖训练样本集合的正例 $Mother(\text{James}, \text{Mike})$ 、且不覆盖任意反例，因此算法学习结束。

当学习得到 $(\forall x)(\forall y)(\forall z)(Father(z, y) \wedge Couple(x, z) \rightarrow Mother(x, y))$ 这一推理规则后，由题意可知 $Father(\text{David}, \text{Ann})$ 和 $Couple(\text{James}, \text{David})$ ，因此可推理得到新的知识 $Mother(\text{James}, \text{Ann})$ ，即 James 和 Ann 的关系为 $Mother$ 关系。

10. 如图 1，试运用路径排序算法推出 James 和 Ann 的 *Mother* 关系。

解 (1) 目标关系: *Mother*

(2) 对于目标关系 *Mother*，生成四组训练样例，一个为正例、三个为负例:

正例: (James, Mike)

负例: (James, David), (David, Ann), (David, Mike)

(3) 从知识图谱采样得到路径，每一路径链接上述每个训练样例中两个实体:

(James, Mike)对应路径: *Couple* $\rightarrow$ *Father*

(James, David)对应路径: *Mother* $\rightarrow$ *Father*⁻¹ (*Father*⁻¹与 *Father*为相反关系)

(David, Ann)对应路径: *Father* $\rightarrow$ *Sibling*

(David, Mike)对应路径: *Couple* $\rightarrow$ *Mother*

(4) 对于每一个正例/负例，判断上述四条路径可否链接其包含的两个实体，将可链接（记为 1）和不可链接（记为 0）作为特征，于是每一个正例/负例得到一个四维特征向量:

(James, Mike): {1, 0, 0, 0}, 1}

(James, David): {0, 1, 0, 0}, -1}

(David, Ann): {0, 0, 1, 0}, -1}

(David, Mike): {0, 0, 1, 1}, -1}

(5) 依据(4)中的训练样本，训练分类器 *M*。

(6) 预测。对于样例 (James, Ann)，得到其特征值为 [1, 0, 0, 0]，将特征向量输入到分类器 *M* 中，分类器 *M* 给出分类结果为 1，*Mother*(David, Ann) 成立。

11. 表 1 给出了某所大学不同系别在录取学生过程中申请人数、申请人性别以及录取人数的统计数据。请对这些数据进行分析，解释其在录取过程中是否存在所谓的“歧视女生”问题？

表 1 申请人数与录取人数数据

系别	男性申请者	录取	比例 /%	女性申请者	录取	比例 /%
英语	825	512	62	108	89	82
俄语	560	353	63	25	17	68

西班牙 语	417	138	33	375	131	35
意大利 语	373	22	6	341	24	7
总计	2175	1024	47	849	261	31

解 下面我们用本章节式 2.4.4（调整公式）来求解是否存在“女性歧视”问题。用 $X = 1$ 表示男性， $X = 0$ 表示女性； $Y = 1$ 表示录取； $Z = 0, 1, 2, 3$ 分别表示英语、俄语、西班牙语和意大利语，则有：

$$\begin{aligned}
 &P(Y = 1|do(X = 1)) \\
 &= P(Y = 1|X = 1, Z = 0)P(Z = 0) + P(Y = 1|X = 1, Z = 1)P(Z = 1) \\
 &\quad + P(Y = 1|X = 1, Z = 2)P(Z = 2) + P(Y = 1|X = 1, Z = 3)P(Z = 3)
 \end{aligned}$$

带入表 1 中数据，可得男性被录取的因果效应为：

$$\begin{aligned}
 &P(Y = 1|do(X = 1)) \\
 &= 0.62 \times \frac{(825 + 108)}{(2175 + 849)} + 0.63 \times \frac{(560 + 25)}{(2175 + 849)} \\
 &\quad + 0.33 \times \frac{(417 + 375)}{(2175 + 849)} + 0.06 \times \frac{(373 + 341)}{(2175 + 849)} = 0.41376
 \end{aligned}$$

类似地，可以求得女性被录取的因果效应为：

$$\begin{aligned}
 &P(Y = 1|do(X = 0)) \\
 &= 0.82 \times \frac{(825 + 108)}{(2175 + 849)} + 0.68 \times \frac{(560 + 25)}{(2175 + 849)} \\
 &\quad + 0.35 \times \frac{(417 + 375)}{(2175 + 849)} + 0.07 \times \frac{(373 + 341)}{(2175 + 849)} = 0.49274
 \end{aligned}$$

最后，我们发现女性录取率（0.49274）比男性录取率（0.41376）要高，即不存在所谓的“女性歧视”。

12.图 2 给出了不同变量之间的依赖关系，请写出因果图 $\mathcal{H}$ 中 8 个变量之间的联合概率形式，并区分哪些变量是内生变量、哪些变量是外生变量。




图 2 因果图 $\mathcal{H}$

解 使用乘积分解规则:

$$\begin{aligned}
 P(X_1, X_2, X_3, X_4, X_5, X_6, X_7, X_8) \\
 &= P(X_1) \times P(X_2|X_4, X_5) \times P(X_3|X_1) \times P(X_4|X_1, X_3, X_5) \\
 &\quad \times P(X_5) \times P(X_6|X_3) \times P(X_7|X_4, X_6, X_8) \times P(X_8|X_5)
 \end{aligned}$$

外生变量: X_1, X_5 ; 内生变量: $X_2, X_3, X_4, X_6, X_7, X_8$

13*. 给出五个可能的限定集 Z , 使其阻塞图 2 因果图 $\mathcal{H}$ 中节点 X_6 和节点 X_8 .

解 为了阻塞节点 X_6 和节点 X_8 , 我们需要让从节点 X_6 到节点 X_8 的所有路径满足 D -分离性质。从节点 X_6 到节点 X_8 共有以下 7 条路径:

P1 $X_6 \rightarrow X_7 \leftarrow X_8$ (基于定义 2.18(2), 节点 X_7 不能在限定集 Z 中)

P2 $X_6 \leftarrow X_3 \rightarrow X_4 \rightarrow X_7 \rightarrow X_8$ (基于定义 2.18, 节点 X_3 或 X_4 或 X_7 需要出现在限定集 Z 中)

P3 $X_6 \leftarrow X_3 \rightarrow X_4 \leftarrow X_5 \rightarrow X_8$ (基于定义 2.18, 节点 X_3 或 X_5 出现在 Z 中, 或者节点 X_4 不出现在 Z 中)

P4 $X_6 \leftarrow X_3 \rightarrow X_4 \rightarrow X_2 \leftarrow X_5 \rightarrow X_8$ (基于定义 2.18, 节点 X_3 或 X_4 或 X_5 出现在 Z 中, 或者节点 X_2 不出现在 Z 中)

P5 $X_6 \leftarrow X_3 \leftarrow X_7 \rightarrow X_4 \rightarrow X_7 \rightarrow X_8$ (基于定义 2.18, 节点 X_3 或 X_7 或 X_4 或 X_7 出现在 Z 中即可)

P6 $X_6 \leftarrow X_3 \leftarrow X_7 \rightarrow X_4 \leftarrow X_5 \rightarrow X_8$ (基于定义 2.18, 节点 X_3 或 X_7 或 X_5 出现在 Z 中, 或者节点 X_4 不出现在 Z 中)

P7 $X_6 \leftarrow X_3 \leftarrow X_7 \rightarrow X_4 \rightarrow X_2 \leftarrow X_5 \rightarrow X_8$ (基于定义 2.18, 节点 X_3 或 X_7 或 X_4 或 X_5 出现在 Z 中, 或者节点 X_2 不出现在 Z 中)

P8: $X_6 \rightarrow X_7 \leftarrow X_4 \leftarrow X_5 \rightarrow X_8$

P9: $X_6 \rightarrow X_7 \leftarrow X_4 \rightarrow X_2 \leftarrow X_5 \rightarrow X_8$

综上, 能让从节点 X_6 到节点 X_8 的所有路径满足 D -分离性质的限定集为:

所有包含节点 X_3 或 $\{X_4, X_5\}$ 且不包含节点 X_7 的限定集, 例如 $\{X_3\}$, $\{X_3, X_4\}$ 等。

第三章 搜索探寻与问题求解

1. 以下关于用搜索算法求解最短路径问题的说法中，不正确的是（ ）。
- A. 给定两个状态，可能不存在两个状态之间的路径；也可能存在两个状态之间的路径，但不存在最短路径（如考虑存在负值的回路情况）。
 - B. 假设状态数量有限，当所有单步代价都相同且大于0时，深度优先的图搜索是最优的。
 - C. 假设状态数量有限，当所有单步代价都相同且大于0时，广度优先的图搜索是最优的。
 - D. 图搜索算法通常比树搜索算法的时间效率更高。

答案：B

A 如果图不连通，则可能不存在路径。如果图中存在负值回路（当然还有其他情况），则可能不存在最短路径。

B 显然不是最优的。

C 在这种情况下，节点所在层数和其路径长度是成正比的，因此优先扩展浅层节点等价于优先扩展路径代价小的节点，这在图搜索中是最优的（可参见 Dijkstra 算法）。

D 因为图搜索是在树搜索的基础上进一步剪枝，因此扩展的节点数量通常更少。

2. 以下关于启发函数和评价函数的说法中正确的是（ ）。
- A. 启发函数不会过高估计从当前节点到目标结点之间的实际代价。
 - B. 取值恒为0的启发函数必然是可容的。
 - C. 评价函数通常是对当前节点到目标节点距离的估计。
 - D. 如果启发函数满足可容性，那么在树搜索 A* 算法中节点的评价函数值按照扩展顺序单调非减；启发函数满足一致性时图搜索 A* 算法也满足该性质。

答案：D

A 只有可容的启发函数才不会过高估计从当前节点到目标结点之间的实际代价。

B 如果存在负值边，则很容易构造反例。

C 启发函数通常是对当前节点到目标节点距离的估计，评价函数不一定有实际意义。

D 根据对 A* 算法的分析，不难证明。

3. 假如可以对围棋的规则做出如下修改，其中哪个修改方案不影响使用本章介绍的 Minimax 算法求解该问题？（ ）
- A. 由双方轮流落子，改为黑方连落两子后白方落一子。
 - B. 双方互相不知道对方落子的位置。
 - C. 由两人对弈改为三人对弈。
 - D. 终局时黑方所占的每目（即每个交叉点）计1分，且事先给定了白方在棋盘上每个位置取得一目所获取的分数，假设这些分数各不相同。双方都以取得最高得分为目标。

答案：A

A 只需要重新定义黑方的动作为每次落两子即可。

- B 导致问题中信息不完全，因此 Minimax 算法无法求解。
- C 导致问题不再是两人对抗问题，每个人的目标不能再简单地用最大化/最小化某一个人的分数来衡量。
- D 使该问题不是零和博弈。白方最大化自己的分数不一定必须最小化黑方的分数。

4. 下列关于探索与利用的说法中，不正确的是（ ）。
- A. 在多臂赌博机问题中，过度探索会导致算法很少主动去选择比较好的摇臂。
 - B. 在多臂赌博机问题中，过度利用可能导致算法对部分臂膀额奖励期望估计不准确。
 - C. 在 ϵ 贪心算法中， ϵ 的值越大，表示算法越倾向于探索。
 - D. 在多臂赌博机问题中，某时刻 UCB1 算法选择的臂膀置信上界为 R ，则此时任意摇动一个臂膀，得到的硬币数量不会超过 R 。

答案：D

A、B、C 显然正确。

D 中置信上界的含义是样本取值以极大的概率不会超过置信上界，并不是说不可能超过。

5. 下列关于蒙特卡洛树搜索算法的说法中，不正确的是（ ）。
- A. 选择过程体现了探索与利用的平衡。
 - B. 算法进入扩展步骤时，当前节点的所有子节点必然都未被扩展。
 - C. 模拟步骤采取的策略与选择步骤不一定要相同。
 - D. 反向传播只需要更新当前路径上已被扩展的节点。

答案：B

A 选择过程中 UCB1 算法即体现了探索与利用的平衡。

B 只要有一个子节点未被扩展，算法就会进入扩展步骤。

C 模拟步骤的策略不一定要和选择步骤相同，模拟步骤通常会采取更简单的策略。

D 对。更新当前路径上的节点，且不在搜索树中的当然不用更新。

6. 如图 1 所示，假设每个节点代表一个状态，节点之间的箭头表示状态转移关系，箭头旁的数字表示状态转移的代价。若使用以下搜索算法寻找从状态 A 到状态 I 的路径，请画出算法终止（找到第一条路径）时的搜索树，并在搜索树中标出节点的扩展顺序，以及找到的路径。若有多个节点拥有相同的扩展优先度，则优先扩展对应路径字典序较小的节点。
- 1) 基于树搜索的广度优先搜索。
 - 2) 基于图搜索的深度优先搜索。






图 1 状态转移图

答案：下图中红线表示路径，节点旁的数字表示扩展顺序。

(1)



(2)



7. 考虑图 1 中的问题，给定每个状态的启发函数如表 1 所示。若仍以状态 A 为初始状态、状态 I 为终止状态，请分别使用以下算法求解从 A 到 I 的路径，并按照第 6 题中的方法画出搜索树。若有多个节点拥有相同的扩展优先度，则优先扩展对应路径字典序较小的节点。

表 1 启发函数的取值。


状态	A	B	C	D	E	F	G	H	I
启发函数	5	4	3	2	5	5	2	1	0

(1) 基于树搜索的贪婪最佳优先搜索。


(2) 基于图搜索的 A*算法。

答案：下图中红线表示路径，节点旁的数字表示扩展顺序。

(1)



(2)



8. 根据问题 7 中的搜索过程，回答下列问题。

- (1) 贪婪最佳优先搜索和 A* 算法均能找到最短路径，且贪婪最佳优先搜索扩展的节点数更少，这是否与正文中的结论“A* 搜索是在已知信息下同类搜索策略中最优的”相矛盾，为什么？
- (2) 不难验证，问题 7 中给出的启发函数既是可容的也是一致的，从这个角度来说这是一个“好”的启发函数。显然这个启发函数并不足够“好”，以至于 A* 算法在该问题中效率低于贪婪最佳优先搜索。那么怎样的启发函数才能提高搜索效率？搜索效率最高时启发函数应该如何取值？


答案：

- (1) 不矛盾。贪婪最佳优先搜索并不具有最优性，本题中的例子只是它能找到最优解的一个特例。“A* 搜索是在已知信息下同类搜索策略中最优的”，其含义是：额外信息仅包括当前的启发函数时，所有能够保证最优性（即在任意有最短路径的问题中都能找到最短路径）的算法中，A* 算法扩展的节点数量是最少的。
- (2) 启发函数在满足可容性或一致性的基础上，其值越接近当前节点到终止节点的最小代价，搜索的效率越高。当启发函数值等于当前节点到终止节点的最小代价时，算法每一步都会朝着最优的方向探索，以 $O(m)$ 的复杂度得到最优解。


9. 图 2 展示了一棵 Minimax 搜索树，可采用 alpha-beta 剪枝算法进行对抗搜索。假设对于每个节点的后继节点，算法按照从左向右的方向扩展。同时假设当 alpha 值等于 beta 值时，算法不进行剪枝。请问：

- (1) 对图 2(a) 中所示搜索树进行搜索，请画出在算法结束时搜索树的状态，用“×”符号标出被剪枝的子树，并计算该算法扩展的节点数量。
- (2) 图 2(b) 展示了和图 2(a) 中完全相同的搜索树，只不过对搜索算法的顺序做了一些调整（扩展顺序交换的节点用红色虚线框标出）。请画出在算法结

束时搜索树的状态，用“×”符号标出被剪枝的子树，并计算该算法扩展的节点数量。



(a)




(b)

图 2 一棵 Minimax 搜索树。


1. 答案：扩展情况如下。显然扩展顺序会影响最终扩展的节点数量（算法时间效率）。

(1) 扩展节点数量为 20。




(2) 扩展节点数量为 25。

节点的 UCB 值从左到右分别为 $\frac{6}{7} + \sqrt{\frac{2 \ln 4}{7}} = 7.67$, $\frac{2}{7} + \sqrt{\frac{2 \ln 4}{7}} = 3.67$, $\frac{7}{7} + \sqrt{\frac{2 \ln 4}{7}} = 8.67$, 因此第二步选择奖励为 7 的节点。如下图所示。



(2) 由于此时已经到达叶子节点，因此不需要进行扩展和模拟过程，反向传播后结果如下图所示



(3) 算法在很长一段时间内都会选择奖励为 7 的节点，而不会探索奖励为 9 的节点。当实验次数足够多时，第二层左侧的节点的 UCB 值最终会超过第二层中间节点的 UCB 值，因此只要实验次数足够多，算法是有可能探索到奖励为 9 的节点的。如果希望提高算法的效率，可考虑加大探索的力度，即取一个更大的超参数 C 。不难验证，在原题中的状态下，取 $C = 10$ 即可令算法选择第二层左侧的节点。

11. 本章 3.2.4 小节中证明了在启发函数满足一致性时图搜索 A* 算法具有最优性，证明过程中用到了一个没有详加说明的结论：给定一条从 s_1 到 s_k 的最短路径 $s_1 \rightarrow s_2 \rightarrow \dots \rightarrow s_k$ ，对于任意 $1 < i < k$ 和任意一条从 s_1 到 s_i 的最短路径 P ，则路径 $P \rightarrow s_{i+1} \rightarrow \dots \rightarrow s_k$ 仍然是 s_1 到 s_k 的一条最短路径。试证明该结论。

答案：假设 $s_1 \rightarrow \dots \rightarrow s_i$ 的代价为 C_1 , $s_i \rightarrow \dots \rightarrow s_k$ 的代价为 C_2 , 由于 $s_1 \rightarrow s_2 \rightarrow \dots \rightarrow s_k$ 是一条最短路径, 因此从 s_1 到 s_k 的最小代价 $C^* = C_1 + C_2$ 。

已知路径 P 是从 s_1 到 s_i 的最短路径, 因此 P 的代价 $C_1^* \leq C_1$, 所以 $C^* = C_1 + C_2 \geq C_1^* + C_2$, 即路径 $P \rightarrow s_{i+1} \rightarrow \dots \rightarrow s_k$ 的代价小于等于从 s_1 到 s_k 最短路径的代价, 因此 $P \rightarrow s_{i+1} \rightarrow \dots \rightarrow s_k$ 必然也为一条最短路径。

12. 针对本章正文中算法 3.4.1 中给出的蒙特卡洛树搜索算法的伪代码, 回答以下问题:

- (1) 函数 BackPropagate 中的第 3 行为何要减去而不是加上终局得分? 如果要修改为加上终局得分, 那么该得分应该以哪位玩家为视角得到的分数?
- (2) 算法 3.4.1 给出了利用蒙特卡洛树搜索算法求解对抗搜索问题的流程, 如果要将蒙特卡洛树搜索应用于非对抗搜索, 应该如何修改该算法?

答案：

- (1) 因为记录该分数是为了让当前节点的父节点选择一个置信上界最大的孩子节点, 由于要最大化父节点玩家的收益相当于最小化当前玩家的收益, 因此此处需要减去当前玩家的收益。如果要修改为加上终局得分, 该得分应该从当前节点的父节点或子节点玩家的角度来计算。
- (2) 关键在于修改 BackPropagate 函数的第三行, 由于不存在两个玩家对抗, 此处只要加上终局奖励得分 (或代价的相反数) 即可。

13. (*) 假设一棵 Minimax 搜索树的最大路径长度为 m , 每个非叶子结点恰好有 b ($b \geq 2$) 个孩子节点。若采用 alpha-beta 剪枝算法求解该问题, 试证明在本章正文图 3.3.11 中所示最优情况下, 算法扩展节点数量的上界为 $O(b^{\lfloor \frac{m+1}{2} \rfloor})$ 。

答案：当搜索树的高度 (最长路径长度) 为 m 且是一棵满 b 叉树时, 假设 alpha-beta 剪枝扩展的最少节点数量为 $f(m)$ 。如本章正文中图 3.3.11 所示, 观察其第二层的节点, 不难发现: 因为第二层最左侧节点继承了根节点 ($-\infty, +\infty$) 的范围, 因此对该节点所在的子树进行搜索等价于树的高度为 $m-1$ 的原问题, 因此扩展节点数量最少为 $f(m-1)$; 考虑第二层的其余 $b-1$ 个节点所在的子树, 最优情况下这些高度为 $m-1$ 的子树的每个第一层节点扩展 1 个子节点, 每个第二层节点扩展 b 个子节点, 每个第三层节点扩展 1 个

子节点，每个第四层节点扩展 b 个子节点，如此循环。因此每棵子树扩展节点数为

$$\begin{aligned}
 & 1 + 1 + b + b + \dots + b^{\lfloor \frac{m-2}{2} \rfloor} + b^{\lfloor \frac{m-1}{2} \rfloor} \\
 & \leq 2(1 + b + \dots + b^{\lfloor \frac{m-1}{2} \rfloor}) \\
 & = 2 \frac{(b^{\lfloor \frac{m-1}{2} \rfloor + 1} - 1)}{(b - 1)} \\
 & < 2 \frac{b^{\lfloor \frac{m-1}{2} \rfloor + 1}}{\frac{b}{2}} \\
 & = 4b^{\lfloor \frac{m-1}{2} \rfloor}
 \end{aligned}$$

由此可得递推关系

$$\begin{aligned}
 f(m) & < f(m-1) + 4(b-1)b^{\lfloor \frac{m-1}{2} \rfloor} + 1 \\
 f(m-1) & < f(m-2) + 4(b-1)b^{\lfloor \frac{m-2}{2} \rfloor} + 1 \\
 & \dots < \dots
 \end{aligned}$$

不等式左右两边同时求和，可得

$$\begin{aligned}
 f(m) & < f(0) + m + 4(b-1)(b^{\lfloor \frac{0}{2} \rfloor} + b^{\lfloor \frac{1}{2} \rfloor} + \dots + b^{\lfloor \frac{m-1}{2} \rfloor}) \\
 & \leq 1 + m + 8(b-1)(1 + b + \dots + b^{\lfloor \frac{m-1}{2} \rfloor}) \\
 & = 1 + m + 8(b-1) \frac{b^{\lfloor \frac{m-1}{2} \rfloor + 1} - 1}{b - 1} \\
 & = 8b^{\lfloor \frac{m+1}{2} \rfloor} + m - 7 \\
 & = O(b^{\lfloor \frac{m+1}{2} \rfloor} + m)
 \end{aligned}$$

在 b 和 m 足够大时，显然 $b^{\lfloor \frac{m+1}{2} \rfloor} > m$ ，因此算法在最优情况下的时间复杂度为 $O(b^{\lfloor \frac{m+1}{2} \rfloor})$ 。

14. (*) Dijkstra 算法是一个著名的求解最短路径的图搜索算法，该算法令每个节点评价函数的值为该节点对应路径的代价（即正文中定义的 $g(n)$ 函数）。

(1) 当图中不存在负值代价时，Dijkstra 算法满足最优性。试根据本章中对图搜索 A* 算法最优性的讨论，证明该结论。

(2) 假设我们已经通过其他方法证明了(1)中的结论，试根据该结论证明，启发函数满足一致性时，A*算法满足最优性。

答案：

(1) 令启发函数 $h(n) \equiv 0$ ，则图搜索的 A* 算法退化为 Dijkstra 算法。对于任意一个节点 n ，假设通过动作 a 能得到后继节点 n' ，当图中没有负值边，即单步代价 $c(n, a, n') \geq 0$ 时，有 $h(n') + c(n, a, n') = c(n, a, n') \geq 0 = h(n)$ ，可知恒为 0 的启发函数满足一致性。因此此时的图搜索 A* 算法——Dijkstra 算法——是最优的。

(2) 跟据原状态转移图 G ，构造一个新的状态转移图 G' ，其中状态和状态转移关系不变，只对状态转移代价进行调整。新的单步代价定义为 $c'(n, a, n') := c(n, a, n') + h(n') - h(n)$ ，若启发函数满足一致性，则显然 $c'(n, a, n') \geq 0$ 。根据(1)中结论，可知在 Dijkstra 算法在 G' 能够找到最优解。

首先证明，给定起始和终止状态 s_1 和 s_k ，则在图 G' 中找到的任意一条最短路径，必然也是 G 中的最短路径。考虑 G' 中的最短路径 $n_1, n_2, \dots, n_k$ （按照本章中的定义，严格来说这不是一条路径，但通过这些节点的状态能找到一条路径。以下为了方便说明，将节点序列也称为路径。），其代价为

$$\begin{aligned} & c'(n_1, a_1, n_2) + c'(n_2, a_2, n_3) + \dots + c'(n_{k-1}, a_{k-1}, n_k) \\ &= [c(n_1, a_1, n_2) + h(n_2) - h(n_1)] + \dots \\ & \quad + [c(n_{k-1}, a_{k-1}, n_k) + h(n_k) - h(n_{k-1})] \\ &= c(n_1, a_1, n_2) + c(n_2, a_2, n_3) + \dots + c(n_{k-1}, a_{k-1}, n_k) + h(n_k) \\ & \quad - h(n_1) \end{aligned}$$

当初始状态和终止状态给定时， $h(n_k) - h(n_1)$ 与路径本身无关，因此可以认为路径在 G' 中的代价是它在 G 中代价加上一个与路径无关的常数，因此 G' 中的最短路径必然也是 G 中的最短路径。

接着证明, 给定起始和终止状态 s_1 和 s_k , 对于任意一个在 G 上搜索的 A* 算法流程, 必然存在一个在 G' 上的 Dijkstra 算法流程与其拥有相同的节点扩展顺序 (称在不同算法中对应路径相同的节点为同一个节点), 因此这两个算法会找到同一条从 s_1 到 s_k 的路径。不妨称 G 上的 A* 算法为算法 A1, G' 上的 Dijkstra 算法为算法 A2。对于 A1 搜索树中的任意节点 n , 可找到 A2 搜索树中对应相同路径的节点 n' , 根据上一段中的论证过程, 可知 $g(n') = g(n) + h(n) - h(n_1)$, 其中 n_1 为根节点。那么算法 A1 (A* 算法) 中评价函数为 $f(n) = g(n) + h(n)$, A2 算法 (Dijkstra 算法) 中评价函数 $f(n') = g(n')$, 因此可得等式 $f(n) = f(n') + h(n_1)$ 。即, 当根节点确定时, 算法 A1 和算法 A2 中对应同一路径的节点其评价函数值只相差一个常数。根据这个性质, 不难用数学归纳法证明, 对于任意一个算法 A1 可能导致的节点扩展顺序 (此处强调任意是因为评价函数相同的节点扩展顺序可能不确定), 都存在一个 A2 算法的扩展顺序与之相同。由于篇幅限制, 此处省略具体的数学归纳法证明。

综上所述, 给定起始和终止状态 s_1 和 s_k , 若 A* 算法找到了一条路径 P , 则该路径必然也能在图 G' 上被 Dijkstra 算法找到。根据问题(1)中的结论, 路径 P 是图 G' 上从 s_1 到 s_k 的最短路径。又根据上述证明, 路径 P 也是图 G 上从状态 s_1 和 s_k 的最短路径, 至此 A* 算法的最优性得证。

第四章 机器学习 做决策树

1. 请判断下面说法是否正确：线性判别分析是在最大化类间方差和类内方差的比值（ ）

- A. 正确
- B. 错误

该题选项 A

2. 在决策树建立过程中，使用一个属性对某个节点对应的数据集合进行划分后，结果具有高信息熵（high entropy），对于结果的描述，最贴切的是（ ）

- A. 纯度高
- B. 纯度低
- C. 有用
- D. 无用
- E. 以上描述都不贴切

该题选项 B

3. 在一个监督学习任务中，每个数据样本有 4 个属性和一个类别标签，每种属性分别有 3、2、2 和 2 种可能的取值，类别标签有 3 种不同的取值。请问可能有多少种不同的样本？（注意，并不是在某个数据集中最多有多少种不同的样本，而是考虑所有可能的样本）（ ）

- A. 3
- B. 6
- C. 12
- D. 24
- E. 48
- F. 72

该题选项 F

4. 关于支持向量机，哪一种选择能正确填充下面的说法（ ）

支持向量机是一种__模型，其目标是__分类间隔

- A. 生成，最大化
- B. 生成，最小化
- C. 判别，最大化
- B. 判别，最小化

该题选项 C

5. 以下哪种方法不属于监督学习方法（ ）

- A. 聚类
- B. 决策树
- C. 线性回归
- D. 朴素贝叶斯

- E. 支持向量机
 - F. 以上都不属于监督学习方法
- 该题选项 A

6. 在 Adaboosting 的迭代中, 从第 t 轮到第 $t+1$ 轮, 某个被错误分类样本的惩罚被增加了, 可能因为该样本 ()

- A. 被第 t 轮训练的弱分类器错误分类
- B. 被第 t 轮后的集成分类器 (强分类器) 错误分类
- C. 被到第 t 轮为止训练的大多数弱分类器错误分类
- D. B 和 C 都正确
- E. A, B 和 C 都正确

该题选项 A

7. 可以从最小化每个类簇的方差这一视角来解释 K 均值聚类的结果, 下面对这一视角描述不正确的是 ()

- a) 最终聚类结果中每个聚类集合中所包含数据呈现出来差异性最小
- b) 每个样本数据分别归属于与其距离最近的聚类质心所在聚类集合
- c) 每个簇类的方差累加起来最小
- d) 每个簇类的质心累加起来最小

该题选项 d

8. 下面对相关性(correlation)和独立性(independence)描述不正确的是 ()

- a) 如果两维变量线性不相关, 则皮尔逊相关系数等于 0
- b) 如果两维变量彼此独立, 则皮尔逊相关系数等于 0
- c) “不相关”是一个比“独立”要强的概念, 即不相关一定相互独立
- d) 独立指两个变量彼此之间不相互影响

该题选项 c

9. 下面对主成分分析的描述不正确的是 ()

- a) 主成分分析是一种特征降维方法
- b) 主成分分析可保证原始高维样本数据被投影映射后, 其方差保持最大
- c) 在主成分分析中, 将数据向方差最大方向进行投影, 可使得数据所蕴含信息没有丢失, 以便在后续处理过程中各个数据“彰显个性”
- d) 在主成分分析中, 所得低维数据中每一维度之间具有极大相关度

该题选项 d

10. 下面对特征人脸算法描述不正确的是 ()

- a) 特征人脸方法是一种应用主成分分析来实现人脸图像降维的方法
- b) 特征人脸方法是用一种称为“特征人脸(eigenface)”的特征向量按照线性组合

形式来表达每一张原始人脸图像

- c) 每一个特征人脸的维数与原始人脸图像的维数一样大
- d) 特征人脸之间的相关度要尽可能大

该题选项 d

11. 在潜在语义分析中，给定 M 个单词和 N 个文档所构成的单词-文档矩阵 (term-document) 矩阵，对其进行分解，将单词或文档映射到一个 R 维的隐性空间。下面描述不正确的是 ()

- a) 单词和文档映射到隐性空间后具有相同的维度
- b) 通过矩阵分解可重建原始单词-文档矩阵，所得到的重建矩阵结果比原始单词-文档矩阵更好捕获了单词-单词、单词-文档、文档-文档之间的隐性关系
- c) 这一映射过程中需要利用文档的类别信息
- d) 隐性空间维度的大小由分解过程中所得对角矩阵中对角线上不为零的系数个数所决定

该题选项 c

12. 假设有两批从同样的真实数据分布中采样得到去完成同一任务的数据集 A 和 B。A 包含 100K 数据，B 包含 10K 数据。按照 9:1 这一同样比例随机将 A 和 B 分别划分为训练集和测试集。图 1 给出了数据集 A 和数据集 B 随着模型复杂度增加所对应训练误差 (A, Train 以及 B, Train) 和测试误差 (A, Test 以及 B, Test) 的曲线图。请指出哪个图正确表示了随着模型复杂度增加所对应训练误差和测试误差的变化曲线图。




图 1 数据集 A 和数据集 B 随模型复杂度增加所对应的训练误差和测试误差变化示意图

12. 参考答案 (A 图是正确的) :

1. 对于每个数据集, 随着模型复杂度增大, 模型在训练集上的错误率会不断下降, 而在测试集上的错误率会先下降后上升。
2. 随着模型复杂度增大, 在更大的数据集 A 上模型更难拟合, 因此也就不容易过拟合, 但具有更好的泛化性。所以合理的猜测是, 曲线 (A, Train) 会在 (B, Train) 的上方, 曲线 (A, Test) 会在 (B, Test) 的下方, 而曲线 (A, Test) 达到过拟合的转折点会比而曲线 (B, Test) 更靠后一些。

13. 加入 L_2 标准化 (normalization) 后, 对于包含参数 w 的线性回归损失函数的标准形式为:

$$L = (Y - Xw)^T(Y - Xw) + \lambda w^T w \quad \text{其中 } \lambda > 0$$

(1) 假设 L_2 标准化项被误写为 $\lambda Y^T Y$, 请解释为什么该项起不到标准化的作用。

(2) 在上述 L_2 标准化中, 如果 λ 小于 0, 请解释为什么起不到标准化的作用。

13. 参考答案:

(1)

该标准化项与参数 w 无关, 该项对 w 的导数永远为 0, 对 w 的优化求解没有作用。

(2)

L_2 标准化项通过惩罚过大的参数 w 来避免过拟合, λ 小于 0 意味着该损失函数倾向于更大的 w , 从而激励过拟合, 失去了标准化的作用。

14. 考虑下面一个数据集:

序号	出去玩	天气状况	有同伴	零花钱	特殊节日	心情指数 (1 差-5 好)
1	是	好	无	多	是	5
2	是	一般	有	多	是	5
3	是	一般	有	少	否	1
4	是	一般	有	少	否	3
5	是	一般	有	少	否	5
6	是	好	无	多	是	5

7	是	好	无	多	是	5
8	否	一般	无	多	是	1
9	否	一般	有	少	否	1
10	否	一般	无	少	否	5

对于如上数据，考虑使用 Ada boosting 方法来训练“是否出去玩”强分类器。每个弱分类器可考虑对单个属性的分类，比如对于“心情指数”这一属性，可考虑心情指数>2 和心情指数<4 两个方面。请问答下列问题：

- (1) Ada boosting 在第一轮迭代中将会选择哪一个弱分类器？
- (2) 第一轮迭代前与迭代后每个样本的权重是多少？
- (3) 第二轮迭代选择的弱分类器是哪一个？分类器权重是多少？
- (4) 写出三轮迭代后的强分类器的表达式（每个弱分类器可用字母替代）

14. 参考答案：

- (1) 心情指数大于 1 出去玩，等于 1 不出去玩。

(2)

迭代前：

1/10	1/10	1/10	1/10	1/10	1/10	1/10	1/10	1/10	1/10
------	------	------	------	------	------	------	------	------	------

迭代后：

1/16	1/16	4/16	1/16	1/16	1/16	1/16	1/16	1/16	4/16
------	------	------	------	------	------	------	------	------	------

(3)

有同伴就出去玩，没同伴不出去玩

$$\frac{1}{2} \ln 3$$

(4)

三次迭代的分类器分别为：

C_1 : 心情指数大于 1 出去玩，等于 1 不出去玩

C_2 : 有同伴出去玩，没同伴不出去玩

C_3 : 天气好出去玩，天气不好不出去玩

强分类器可表示为：

$$\text{sign}\left(\frac{1}{2} \ln(4) C_1 + \frac{1}{2} \ln(3) C_2 + \frac{1}{2} \ln\left(\frac{17}{7}\right) C_3\right)$$

* 15. 线性判别分析模型由如下的假设所定义：

$$P(x|y = k) = \frac{e^{\frac{1}{2}(x-\mu_k)^T \Sigma^{-1}(x-\mu_k)}}{\sqrt{2\pi} |\Sigma|^{\frac{1}{2}}}$$

其决策边界由如下的对数几率比值确定：

$$\log \frac{P(y=1|x)}{P(y=0|x)} = \log \frac{P(x|y=1)P(y=1)}{P(x|y=0)P(y=0)}$$

请简要证明线性判别分析的决策边界是线性的。

* 15. 参考答案:

$$\begin{aligned} & \log \frac{P(x|y=1)P(y=1)}{P(x|y=0)P(y=0)} \\ & \propto \log \frac{P(y=1)}{P(y=0)} + \frac{1}{2}(x - \mu_1)^T \Sigma^{-1}(x - \mu_1) \\ & \quad - \frac{1}{2}(x - \mu_0)^T \Sigma^{-1}(x - \mu_0) \\ & \log \frac{P(x|y=1)P(y=1)}{P(x|y=0)P(y=0)} \\ & \propto \log \frac{P(y=1)}{P(y=0)} - \frac{1}{2}(\mu_1)^T \Sigma^{-1}(\mu_1) + \frac{1}{2}(\mu_0)^T \Sigma^{-1}(\mu_0) \\ & \quad + x^T \Sigma^{-1}(\mu_1 - \mu_0) \\ & = b + w^T x \end{aligned}$$

其中 $b = \log \frac{P(y=1)}{P(y=0)} - \frac{1}{2}(\mu_1)^T \Sigma^{-1}(\mu_1) + \frac{1}{2}(\mu_0)^T \Sigma^{-1}(\mu_0)$ 是一个常量, $w =$

$\Sigma^{-1}(\mu_1 - \mu_0)$ 是一个线性参数向量。证毕。

16. 说明在 k-means 算法执行的过程中, 其目标函数 $\sum_{i=1}^K \sum_{x \in G_i} \|x - c_i\|^2$ 是严格

递减的, 并解释为什么 k-means 算法可以确保在有限步内收敛。

参考答案: 在每一次聚类过程中, 每个数据点都被分配到与其距离最近聚类中心

所在集合, 即 $\operatorname{argmin}_{c_j \in C} \|x_i - c_j\|^2$, 因此在聚类步骤中 $\sum_{i=1}^K \sum_{x \in G_i} \|x - c_i\|^2$ 中

的每一项都保持不变或减小, 仅当算法收敛时才会每一项都保持不变。因此, 只要算法没有收敛, 在每一次聚类后目标函数都会减小。

设一组数据点的聚类中心为 z , 则对于该组数据 $\{x_i\}$, $\sum_{i=1}^K (x - z)^2 = \sum_{i=1}^K ((x - \bar{x})^2 + 2(x - \bar{x})(\bar{x} - z) + (\bar{x} - z)^2) = \sum_{i=1}^K (x - \bar{x})^2 + 2(\bar{x} - z) \sum_{i=1}^K (x - \bar{x}) + \sum_{i=1}^K (\bar{x} - z)^2 = \sum_{i=1}^K (x - \bar{x})^2 + \sum_{i=1}^K (\bar{x} - z)^2$, 当 $z = \bar{x}$ 时取最小值。因

此在更新聚类中心的步骤中，对每组数据取均值为新的中心将最小化每一个 $\sum_{x \in G_i} \|x - c_i\|^2$ 。同样，只要算法没有收敛，在每一次更新聚类中心后目标函数都会减小。

综上，在算法收敛前目标函数都将严格递减。因此，k-means 算法不可能两次访问完全相同的聚类情况。而将有限数量的数据点分为 k 类的总可能是有限的，能保证不循环的 k-means 算法一定能够收敛。

17. 结合书中 5.5.1 的例子，根据如下五轮（每轮投掷 10 次硬币）观测的结果，使用 EM 算法分别估计硬币 A 和硬币 B 被投掷为正面的概率。

1	H	H	T	T	T	T	T	H	T	H
2	T	T	H	T	H	H	H	H	T	H
3	T	T	T	T	T	T	T	T	T	T
4	H	T	H	H	H	H	H	H	H	H
5	H	T	T	T	H	H	T	H	H	T

参考答案：
初始化两枚硬币的概率为 0.30 和 0.70

迭代次数	硬币 A 为正面次数	硬币 A 为反面次数	硬币 B 为正面次数	硬币 B 为反面次数	硬币 A 投掷正面概率 θ_A	硬币 B 投掷正面概率 θ_B
1	6.82	18.19	17.18	7.81	0.27	0.69
2	1.89	21.12	22.11	4.87	0.08	0.82
3	1.52	15.16	22.48	10.83	0.09	0.67
4	1.09	10.36	22.91	15.64	0.09	0.59
5	1.01	9.79	22.99	16.21	0.09	0.59

18. EM 算法和 k-均值聚类算法有着非常相似的迭代结构，可以说 k-均值聚类算法是 EM 算法的一种特殊实现。如果将 k-均值聚类中的聚类质心作为隐变量，试从 EM 算法角度来解释 k-均值聚类算法，即描述 k-均值聚类算法的 E 步骤和 M 步骤。

参考答案：

k-means 算法可以被看做 EM 算法的一种特殊实现，其隐变量即为各聚类中心。在 E 步骤中，通过欧氏距离来估计各数据点最有可能归属于哪个聚类中心；在 M 步骤中，通过计算均值更新聚类中心位置来最大化这些数据点属于该聚类中心的可能性。

19. 在机器学习中，总体是特定研究任务中所定义的全部个体集合，样本是从总体中选择出来的个体子集。一般使用从包含有限个体数目的样本中所得到的信息来作出描述总体的一般结论。样本方差 (sample variance) 和总体方差是两个不一样的概念。使用样本均值来估计总体均值是无偏的 (unbiased)，但使用样本方差 s^2 来估计总体方差 σ^2 却是有偏的 (biased)。总体方差 $\sigma^2 = E[(x - \mu)^2]$ ，其中 x 为来自总体的一个样本， μ 是总体均值。假设样本集合 x 包含了 n 个数据 $\{x_1, x_2, x_3, \dots, x_n\}$ ，在了解下面样本均值是总体均值的无偏估计以及 $E[\frac{1}{n} \sum_{i=1}^n (\bar{x} - x_i)^2] = \frac{n-1}{n} \sigma^2$ 的基础上，证明如果样本方差定义为 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ ，则 $E(s^2) = \sigma^2$ 。

a) 样本均值是对总体均值无偏估计的证明过程

证明：

$$\begin{aligned} E[\bar{x}] &= E\left[\frac{x_1 + x_2 + \dots + x_n}{n}\right] \\ &= \frac{1}{n} E[x_1 + x_2 + \dots + x_n] \end{aligned}$$

$$\begin{aligned}
&= \frac{1}{n} (E[x_1] + E[x_2] + \dots + E[x_n]) \\
&= \frac{1}{n} (\mu + \mu + \dots + \mu) \\
&= \frac{n\mu}{n} \\
&= \mu
\end{aligned}$$

可见，样本均值是对总体均值的无偏估计。

$$\text{b) } E \left[\frac{1}{n} \sum_{i=1}^n (\bar{x} - x_i)^2 \right] = \frac{n-1}{n} \sigma^2$$

证明：

$$\begin{aligned}
E \left[\frac{1}{n} \sum_{i=1}^n (\bar{x} - x_i)^2 \right] &= E \left[\frac{1}{n} \sum_{i=1}^n ((\bar{x} - \mu) - (x_i - \mu))^2 \right] \\
&= E \left[\frac{1}{n} \sum_{i=1}^n ((\bar{x} - \mu)^2 \right. \\
&\quad \left. - 2(\bar{x} - \mu)(x_i - \mu) + (x_i - \mu)^2) \right] \\
&= E \left[(\bar{x} - \mu)^2 - \frac{2(\bar{x} - \mu)}{n} \sum_{i=1}^n (x_i - \mu) \right. \\
&\quad \left. + \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \right] \\
&= E \left[(\bar{x} - \mu)^2 - 2(\bar{x} - \mu)^2 + \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \right] \\
&= E \left[-\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \right] - E \left[(\bar{x} - \mu)^2 \right] \\
&= \sigma^2 - \frac{\sigma^2}{n} \\
&= \frac{n-1}{n} \sigma^2
\end{aligned}$$

在上面的证明过程中，利用了如下的结果：

由于 $E(X^2) = [E(X)]^2 + Var(X)$ 、 $Var(a + X) = Var(X)$ 、

$$Var(aX) = a^2 Var(X)$$

因此

$$\begin{aligned} E[(\bar{x} - \mu)^2] &= [E(\bar{x} - \mu)]^2 + Var(\bar{x} - \mu) = Var(\bar{x}) \\ &= Var\left(\frac{x_1 + x_2 + \dots + x_n}{n}\right) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n} \end{aligned}$$

从 $E\left[\frac{1}{n}\sum_{i=1}^n (\bar{x} - x_i)^2\right] = \frac{n-1}{n}\sigma^2$ 可知, $\frac{1}{n}\sum_{i=1}^n (\bar{x} - x_i)^2$ 是对总体方差的一个低估, 因此在用样本方差来代替总体方差时, 需要将样本方差定义为

$\frac{1}{n-1}\sum_{i=1}^n (x_i - \mu)^2$, 这才能从样本方差出发, 得到总体方差 σ^2 , 这是一个无偏估计。

答案:

$$\begin{aligned} \frac{n}{n-1} E\left[\frac{1}{n}\sum_{i=1}^n (\bar{x} - x_i)^2\right] &= E\left[\frac{1}{n-1}\sum_{i=1}^n (\bar{x} - x_i)^2\right] = \frac{n}{n-1} \times \frac{n-1}{n} \sigma^2 \\ &= \sigma^2 \end{aligned}$$

第五章 神经网络与深度学习

1. 下面对误差反向传播 (error back propagation, BP)描述不正确的是 ()
- a) BP 算法是一种将输出层误差反向传播给隐藏层进行参数更新的方法
 - b) BP 算法将误差从后向前传递, 获得各层单元所产生误差, 进而依据这个误差来让各层单元修正各单元参数
 - c) 对前馈神经网络而言, BP 算法可调整相邻层神经元之间的连接权重大小
 - d) 在 BP 算法中, 每个神经元单元可包含不可偏导的映射函数

该题选项: d

2. 以下关于梯度下降和随机梯度下降的说明, 哪些描述是正确的?
- a) 在梯度下降和随机梯度下降中, 为了最小化损失函数, 通常使用循环迭代的方式不断更新模型参数;
 - b) 在每次迭代中, 随机梯度下降需要计算训练集所有样本的误差和, 用于更新模型参数;
 - c) 在每次迭代中, 梯度下降使用所有数据或者部分训练数据, 用于更新模型参数.

该题选项: a 和 c

3. 关于 sigmoid 激活函数, 下列描述正确的是?
- a) 它是凸函数, 凸函数无法解决非凸问题;
 - b) 它可以有负值;
 - c) 它无法配合交叉熵损失函数使用;
 - d) 当输入值过大或者过小时, 梯度趋近于 0, 容易造成梯度消失问题。

该题选项: d

4. 下面对前馈神经网络这种深度学习方法描述不正确的是 ()
- a) 是一种端到端学习的方法
 - b) 是一种监督学习的方法
 - c) 实现了非线性映射
 - d) 隐藏层数目大小对学习性能影响不大

该题选项: d

5. 图 6.4.5 展示了长短时记忆网络的详细结构。如下描述正确的是?
- a) 如果输入 x_t 为 0 向量, 则 $h_t = h_{t-1}$
 - b) 如果 f_t 非常小或者为 0, 则误差不会被反向传播到较早的时间节点
 - c) f_t 、 i_t 和 o_t 的输出是非负数;

d) f_t 、 i_t 和 o_t 的输出可以被看作是概率分布，其输出为非负数且和为 1.

该题选项：c

6. 关于生成对抗网络的训练，以下说法正确的是（ ）

- a) 为了加速生成对抗网络的训练，通常采用交替训练一轮判别器和多轮生成器的方法
- b) 当生成器能够产生足以以假乱真的数据，即 $D(G(z))$ 的输出稳定于接近 1 的值时，训练就完成了
- c) 目标函数需要在训练初期提供足够的梯度，使生成器更快开始产生能够混淆判别器的数据
- d) 生成对抗网络在经过足够长时间的训练后可以确保收敛到全局最优

该题选项：c

7. 在训练生成对抗网络时，发现损失函数的值很小，但生成器产生的数据质量并不高这可能是因为（ ）

- a) 判别器欠拟合
- b) 判别器过拟合
- c) 生成器欠拟合
- d) 生成器过拟合

该题选项：a

8. 请问深度学习和传统的机器学习有什么区别？

数据：深度学习适合处理大数据，机器学习算法更适用于小数据；

硬件：深度学习由于巨大的计算量，需要大量计算资源，比如 GPU，机器学习算法对计算资源的需求相对较低；

特征构建：深度学习试图从数据中学习特征，机器学习中许多特征都需要由行业专家确定，并手工构造；

解决问题方式：深度学习通常利用“端到端”的方式构建模型，机器学习通常将问题分为几个步骤，每个步骤逐一解决，然后将结果组合。

9. (1) 请说明单层感知机为何无法模拟逻辑异或操作？
(2) 请设计一个前馈神经网络，用于拟合异或函数。

(1) 根据图 6.2.可知, 在异或操作中, 点 (0,0) 与 (1,1) 为 0, 点 (0,1) 和 (1,0) 为 1, 由于感知机是线性分类器, 无法构建超平面可以将这两类分开。

(2) 输入层维度为 2, 用于接收两个操作数; 至少有一层隐藏层, 且隐藏层中的神经元需要包含非线性激活函数; 输出层维度为 1, 用于输出结果。

10. 在前馈神经网络中, 所有的参数能否被初始化为 0? 如果不能, 能否全部被初始化为其他相同的值? 为什么?

不能初始化为 0, 也不能被同时初始化为其他相同的值。

如果参数被初始化为相同的值后, 在误差反向传播过程中, 同一层的神经元所接收到的误差都相同, 更新后这些参数的值仍然相同。不管经过多少轮迭代, 同一层神经元的参数保持相同, 因此不同的神经元无法学习到不同特征的重要程度, 失去了深度神经网络学习特征的能力。

11. “编码器-解码器”框架被广泛用于机器翻译中, 其中编码器用于对源语言进行编码, 解码器用于产生目标语言。当编码器编码完毕后, 会将所得信息传给解码器, 同时给解码器“BOS”标签, 告知解码器可以开始解码。解码器依次产生目标语言词汇, 当产生“EOS”标签时解码结束。图 3 给出了通用机器翻译框架, 如果目标语言的词汇量大小为 V , y'_i 为模型预测的 V 维概率向量、 w_i 为所预测词语、 y_i 为真实值。




图 3 机器翻译中“编码-解码”框架

- (1) 写出解码器的损失函数。
- (2) 在模型过程中, 通常会使用“微调”的方式更新预训练词向量。请写出 w_{n-1} 梯度。

答案:

$$(1) L = \sum_{i=1}^{n+1} -y_i * \log y'_i$$

$$(2) l_{n+1} = -y_{n+1} * \log y'_{n+1}$$

$$l_n = -y_n * \log y_n'$$

$$\frac{\partial L}{\partial w_{n-1}} = \frac{\partial l_{n+1}}{\partial y_{n+1}'} * \frac{\partial y_{n+1}'}{\partial h_{n+1}} * \frac{\partial h_{n+1}}{\partial h_n} * \frac{\partial h_n}{\partial w_{n-1}} + \frac{\partial l_n}{\partial y_n'} * \frac{\partial y_n'}{\partial h_n} * \frac{\partial h_n}{\partial w_{n-1}}$$

12. *请证明为什么 LSTM 会解决循环神经网络(RNN)中所遇到的梯度消失问题。

RNN 的计算公式可以写为:

$$c_t = W \cdot [x_t, c_{t-1}] + b$$

假设时序长度为 T, 则在梯度反向传播过程中, T 时刻的误差 l_T 对 W 的梯度为:

$$\frac{\partial l_T}{\partial W} = \sum_{i=1}^T \frac{\partial l_T}{\partial c_T} * (\prod_{j=i+1}^T \frac{\partial c_j}{\partial c_{j-1}}) * \frac{\partial c_T}{\partial W}$$

$\prod_{j=i+1}^T \frac{\partial c_j}{\partial c_{j-1}}$ 中每一项都介于 0-1 之间的小数, 当 T 很大时, $\prod_{j=i+1}^T \frac{\partial c_j}{\partial c_{j-1}}$

值趋近于 0, 从而产生梯度消失问题。

在 LSTM 中, $c_t = f_t \cdot c_{t-1} + i_t \cdot \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$, 因此 $\frac{\partial c_t}{\partial c_{t-1}} = f_t$,

由于 f_t 通常为 1 或者为 0, 当为 1 时, 所有梯度能够在 LSTM 中传递, 当为 0 时, 说明上一时刻的信息对当前时刻没有影响, 因此没有必要传回梯度更新参数。这样, LSTM 解决了 RNN 的梯度消失问题。

第六章 强化学习

1. 下面对强化学习、监督学习和深度卷积神经网络学习的描述正确的是 ()

- A. 评估学习方式、有标注信息学习方式、端到端学习方式
- B. 有标注信息学习方式、端到端学习方式、端到端学习方式
- C. 评估学习方式、端到端学习方式、端到端学习方式
- D. 无标注学习、有标注信息学习方式、端到端学习方式

该题选项 A

2. 在强化学习中，通过哪两个步骤的迭代，来学习得到最佳策略 ()

- A. 价值函数计算与动作-价值函数计算
- B. 动态规划与 Q-Learning
- C. 贪心策略优化与 Q-learning
- D. 策略优化与策略评估

该题选项 D

3. 在强化学习中，哪个机制的引入使得强化学习具备了在利用与探索中寻求平衡的能力 ()

- A. ϵ 贪心策略
- B. 蒙特卡洛采样
- C. 动态规划
- D. 贝尔曼方程

该题选项 A

4. 与马尔可夫奖励过程相比，马尔可夫决策过程引入了哪一个新的元素 ()?

- A. 反馈
- B. 动作
- C. 终止状态
- D. 概率转移矩阵

该题选项 B

5. 在本章内容范围内，“在状态 s ，按照某个策略行动后在未来所获得回报值的

期望”，这句话描述了状态 s 的 ()；“在状态 s ，按照某个策略采取动作 a 后在

未来所获得回报值的期望”，这句话描述了状态 s 的 ()

- A. 策略优化
- B. 价值函数
- C. 动作-价值函数
- D. 采样函数

该题选项 B; C

6. 将图 7.1.2 中的机器人寻路问题简化为图 1 的 2×2 的网格, 假设有位于 s_1 位置的机器人拟从 s_1 这一初始位置向 s_4 这一目标位置移动。机器人每次只能向上或者向右移动一个方格, 到达目标位置 s_4 则会获得奖励且游戏终止, 机器人在移动过程中如果越出方格 (s_d) 则会被惩罚且被损坏、并且游戏终止。奖励值定义如下: 当 $S_{t+1} = s_4$ 时奖励值为 1, 当 $S_{t+1} = s_d$ 时惩罚值为 -1, 其他情况下奖励值为 0。若折扣因子 $\gamma = 0.99$, 智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上, 终止状态 s_4 、 s_d 的价值函数定义为 0, 试通过联立贝尔曼方程给出状态 s_1 、 s_2 、 s_3 的价值函数。




图 1 2×2 的机器人寻路问题

解 根据公式 (7.1.5) 所示的价值函数的贝尔曼方程联立方程组:

$$V_{\pi}(s_1) = R(s_1, \text{上}, s_3) + \gamma V_{\pi}(s_3) = 0 + 0.99 \times V_{\pi}(s_3)$$

$$V_{\pi}(s_2) = R(s_2, \text{上}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times V_{\pi}(s_4)$$

$$\{ V_{\pi}(s_3) = R(s_3, \text{上}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times V_{\pi}(s_d)$$

$$V_{\pi}(s_4) = 0$$

$$V_{\pi}(s_d) = 0$$

解得:

$$V_{\pi}(s_1) = -0.99$$

$$V_{\pi}(s_2) = 1$$

$$\{ V_{\pi}(s_3) = -1$$

$$V_{\pi}(s_4) = 0$$

$$V_{\pi}(s_d) = 0$$

7. 在题 6 中，若每个状态的价值函数都初始化为 0，智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上，试优化智能体在状态 s_3 的策略。（提示：使用策略优化定理）

解 由于机器人每一步只能向上或者向右移动一个方格，首先计算状态 s_3 选择这两个不同动作后分别所得动作-价值函数取值：

$$\begin{aligned} q_{\pi}(s_3, \text{上}) &= \sum_{s' \in S} P(s' | s_3, \text{上}) [R(s_3, \text{上}, s') + \gamma V_{\pi}(s')] \\ &= 1 \times (-1 + 0.99 \times 0) + 0 \times \dots = -1 \\ q_{\pi}(s_3, \text{右}) &= \sum_{s' \in S} P(s' | s_3, \text{右}) [R(s_3, \text{右}, s') + \gamma V_{\pi}(s')] \\ &= 1 \times (1 + 0.99 \times 0) + 0 \times \dots = 1 \end{aligned}$$

可见，智能体在状态 s_3 选择“向上移动一个方格”行动所得回报 $q_{\pi}(s_3, \text{上})$ 值为 -1 、选择“向右移动一个方格”行动所得回报 $q_{\pi}(s_3, \text{右})$ 值为 1 。显然，智能体在状态 s_3 应该选择“向右移动一个方格”行动，这样能够获得更大的回报。

于是，经过策略优化后，状态 s_3 处的新策略为 $\pi'(s_3) = \arg\max_a q_{\pi}(s, a) = \text{右}$ ，则将 s_3 处的策略从“上”更新为“右”。

8. 在题 6 中，，若每个状态的价值函数都初始化为 0，智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上，试使用算法 7.2.5 中的价值迭代算法优化智能体在每个状态下的价值函数和策略，并给出迭代过程。

解 1) 第一次迭代：

$$q_{\pi}(s_1, \text{上}) = R(s_1, \text{上}, s_3) + \gamma V_{\pi}(s_3) = 0 + 0.99 \times 0 = 0$$

$$q_{\pi}(s_1, \text{右}) = R(s_1, \text{右}, s_2) + \gamma V_{\pi}(s_2) = 0 + 0.99 \times 0 = 0$$

$$\pi(s_1) = \operatorname{argmax}_a q_{\pi}(s_1, a) = \text{上}, V_{\pi}(s_1) = q_{\pi}(s_1, \pi(s_1)) = 0$$

$$q_{\pi}(s_2, \text{上}) = R(s_2, \text{上}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times 0 = 1$$

$$q_{\pi}(s_2, \text{右}) = R(s_2, \text{右}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times 0 = -1$$

$$\pi(s_2) = \operatorname{argmax}_a q_{\pi}(s_2, a) = \text{上}, V_{\pi}(s_2) = q_{\pi}(s_2, \pi(s_2)) = 1$$

$$q_{\pi}(s_3, \text{上}) = R(s_3, \text{上}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times 0 = -1$$

$$q_{\pi}(s_3, \text{右}) = R(s_3, \text{右}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times 0 = 1$$

$$\pi(s_3) = \operatorname{argmax}_a q_{\pi}(s_3, a) = \text{右}, V_{\pi}(s_3) = q_{\pi}(s_3, \pi(s_3)) = 1$$

此时的价值函数为：

1	0
0	1

2) 第二次迭代：

$$q_{\pi}(s_1, \text{上}) = R(s_1, \text{上}, s_3) + \gamma V_{\pi}(s_3) = 0 + 0.99 \times 1 = 0.99$$

$$q_{\pi}(s_1, \text{右}) = R(s_1, \text{右}, s_2) + \gamma V_{\pi}(s_2) = 0 + 0.99 \times 1 = 0.99$$

$$\pi(s_1) = \operatorname{argmax}_a q_{\pi}(s_1, a) = \text{上}, V_{\pi}(s_1) = q_{\pi}(s_1, \pi(s_1)) = 0.99$$

$$q_{\pi}(s_2, \text{上}) = R(s_2, \text{上}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times 0 = 1$$

$$q_{\pi}(s_2, \text{右}) = R(s_2, \text{右}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times 0 = -1$$

$$\pi(s_2) = \operatorname{argmax}_a q_{\pi}(s_2, a) = \text{上}, V_{\pi}(s_2) = q_{\pi}(s_2, \pi(s_2)) = 1$$

$$q_{\pi}(s_3, \text{上}) = R(s_3, \text{上}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times 0 = -1$$

$$q_{\pi}(s_3, \text{右}) = R(s_3, \text{右}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times 0 = 1$$

$$\pi(s_3) = \operatorname{argmax}_a q_{\pi}(s_3, a) = \text{右}, V_{\pi}(s_3) = q_{\pi}(s_3, \pi(s_3)) = 1$$

此时的价值函数为：

1	0
0.99	1

3) 第三次迭代：

$$q_{\pi}(s_1, \text{上}) = R(s_1, \text{上}, s_3) + \gamma V_{\pi}(s_3) = 0 + 0.99 \times 1 = 0.99$$

$$q_{\pi}(s_1, \text{右}) = R(s_1, \text{右}, s_2) + \gamma V_{\pi}(s_2) = 0 + 0.99 \times 1 = 0.99$$

$$\pi(s_1) = \arg\max_a q_{\pi}(s_1, a) = \text{上}, V_{\pi}(s_1) = q_{\pi}(s_1, \pi(s_1)) = 0.99$$

$$q_{\pi}(s_2, \text{上}) = R(s_2, \text{上}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times 0 = 1$$

$$q_{\pi}(s_2, \text{右}) = R(s_2, \text{右}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times 0 = -1$$

$$\pi(s_2) = \arg\max_a q_{\pi}(s_2, a) = \text{上}, V_{\pi}(s_2) = q_{\pi}(s_2, \pi(s_2)) = 1$$

$$q_{\pi}(s_3, \text{上}) = R(s_3, \text{上}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times 0 = -1$$

$$q_{\pi}(s_3, \text{右}) = R(s_3, \text{右}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times 0 = 1$$

$$\pi(s_3) = \arg\max_a q_{\pi}(s_3, a) = \text{右}, V_{\pi}(s_3) = q_{\pi}(s_3, \pi(s_3)) = 1$$

当迭代 3 次以后，价值函数收敛，算法终止，此时的价值函数为：

1	0
0.99	1

9. 在题 6 中，，若图 2 表示算法的初始状态，其中 a/b 表示对应状态的动作-价值函数的取值，斜线左侧的 a 表示 $q_{\pi}(s, \text{上})$ ，斜线右侧的 b 表示 $q_{\pi}(s, \text{右})$ 。若 $\alpha = 0.5$ ，试给出算法 7.2.6 中的 Q 学习算法的一个片段的执行过程，并给出执行完该片段后每个状态的策略。

0.1/0	0/0
0.1/0	0.1/0

图2 Q学习算法的初始状态

解 根据算法 7.2.6 中的 Q 学习算法, s_1 为初始状态, 根据当前策略求出智能体应该采取的动作 $a = \operatorname{argmax}_a q_{\pi}(s_1, a) = \text{上}$, 执行这个动作, 得到奖励 $R = 0$ 和进入下一状态 $s' = s_3$, 因此可如下更新对应的动作-价值函数:

$$\begin{aligned} q_{\pi}(s_1, \text{上}) &\leftarrow q_{\pi}(s_1, \text{上}) + \alpha [R + \gamma \max_a q_{\pi}(s', a) - q_{\pi}(s, a)] \\ &= 0.1 + 0.5 \times [0 + 0.99 \times \max\{0, 0.1\} - 0.1] = 0.0995 \end{aligned}$$

此时的 q 函数为:

0.1/0	0/0
0.0995/0	0.1/0

同时令当前状态为 s_3 , 此时智能体应该采取的动作 $a = \operatorname{argmax}_a q_{\pi}(s_3, a) = \text{上}$, 执行这个动作, 得到奖励 $R = -1$ 和进入下一状态 $s' = s_d$, 因此可如下更新对应的动作-价值函数:

$$\begin{aligned} q_{\pi}(s_3, \text{上}) &\leftarrow q_{\pi}(s_3, \text{上}) + \alpha [R + \gamma \max_a q_{\pi}(s', a) - q_{\pi}(s, a)] \\ &= 0.1 + 0.5 \times [-1 + 0.99 \times \max\{0, 0.1\} - 0.1] = -0.4005 \end{aligned}$$

此时算法达到终止状态 s_d , 该片段结束。此时的 q 函数为:

-0.4005/0	0/0
0.0995/0	0.1/0

此时每个状态的策略为:

→	
↑	↑

10. 采样时策略和更新时策略彼此不同的算法称为离策略算法。反之，采样时策略和更新时策略相同的算法称为在策略算法。算法 7.2.7 给出的 Q 学习是一个离策略算法，请给出其对应的在策略版本——Sarsa 算法。

解

函数: Sarsa

输入: 马尔可夫决策过程 $MDP = (S, A, P, R, \gamma)$

输出: 策略 π

```

1  随机初始化  $q_\pi$ 
2  repeat
3       $s \leftarrow$  初始状态
4      repeat
5           $a \leftarrow \text{EpsGreedy}(s, q_\pi, \epsilon)$ 
6          执行动作  $a$ , 观察奖励  $R$  和下一个状态  $s'$ 
7           $a' \leftarrow \text{EpsGreedy}(s', q_\pi, \epsilon)$ 
8           $q_\pi(s, a) \leftarrow q_\pi(s, a) + \alpha[R + \gamma q_\pi(s', a') - q_\pi(s, a)]$ 
9           $s \leftarrow s'$ 
10     until  $s$  是终止状态
11 until  $q_\pi$  收敛
12  $\pi(s) := \arg \max_a q(s, a)$ 

```

11*. 回顾将价值函数作为 Actor-Critic 算法的基准函数的推导过程，若将基准函数设置为 $h(s, a)$ ，指出推导过程中的哪一步不再适用。

解 根据公式(7.3.3),

$$\begin{aligned}
\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) &\propto \mathbb{E}_{s,a \sim \pi} [q_{\pi_{\boldsymbol{\theta}}}(s,a) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s,a \sim \pi} [(q_{\pi_{\boldsymbol{\theta}}}(s,a) - b(s) + b(s)) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s,a \sim \pi} [(q_{\pi_{\boldsymbol{\theta}}}(s,a) - b(s)) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&\quad + \mathbb{E}_{s,a \sim \pi} [b(s) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)]
\end{aligned}$$

其中

$$\begin{aligned}
\mathbb{E}_{s,a \sim \pi} [b(s) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] &= \mathbb{E}_{s \sim \pi} [\sum_a \pi_{\boldsymbol{\theta}}(s,a) b(s) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s \sim \pi} [b(s) \sum_a \pi_{\boldsymbol{\theta}}(s,a) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s \sim \pi} [b(s) \sum_a \pi_{\boldsymbol{\theta}}(s,a) \frac{\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(s,a)}{\pi_{\boldsymbol{\theta}}(s,a)}] \\
&= \mathbb{E}_{s \sim \pi} [b(s) \nabla_{\boldsymbol{\theta}} \sum_a \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s \sim \pi} [b(s) \nabla_{\boldsymbol{\theta}} 1] \\
&= 0
\end{aligned}$$

因此

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \mathbb{E}_{s,a \sim \pi} [(q_{\pi_{\boldsymbol{\theta}}}(s,a) - b(s)) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)]$$

假设 $h(s,a)$ 为 Actor-Critic 算法的基准函数，仿照上面的推导，

$$\begin{aligned}
\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) &\propto \mathbb{E}_{s,a \sim \pi} [q_{\pi_{\boldsymbol{\theta}}}(s,a) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s,a \sim \pi} [(q_{\pi_{\boldsymbol{\theta}}}(s,a) - h(s,a) + h(s,a)) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s,a \sim \pi} [(q_{\pi_{\boldsymbol{\theta}}}(s,a) - h(s,a)) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&\quad + \mathbb{E}_{s,a \sim \pi} [h(s,a) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)]
\end{aligned}$$

其中，对 $\mathbb{E}_{s,a \sim \pi} [h(s,a) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)]$ 中的 a 的期望进行展开，

$$\begin{aligned}
\mathbb{E}_{s,a \sim \pi} [h(s,a) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] &= \mathbb{E}_{s \sim \pi} [\sum_a \pi_{\boldsymbol{\theta}}(s,a) h(s,a) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s,a)] \\
&= \mathbb{E}_{s \sim \pi} [\sum_a \pi_{\boldsymbol{\theta}}(s,a) h(s,a) \frac{\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(s,a)}{\pi_{\boldsymbol{\theta}}(s,a)}] \\
&= \mathbb{E}_{s \sim \pi} [\sum_a h(s,a) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(s,a)]
\end{aligned}$$

$$= \mathbb{E}_{s \sim \pi} [\nabla_{\boldsymbol{\theta}} \sum_a h(s, a) \pi_{\boldsymbol{\theta}}(s, a)]$$

由于 $h(s, a)$ 含有变量 a ，无法再同原推导一样将其放到求和符号外面。而

$\mathbb{E}_{s \sim \pi} [\nabla_{\boldsymbol{\theta}} \sum_a h(s, a) \pi_{\boldsymbol{\theta}}(s, a)]$ 在一般情况下都不为 0，因此无法再得到形如

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \mathbb{E}_{s, a \sim \pi} [(q_{\pi_{\boldsymbol{\theta}}}(s, a) - h(s, a)) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(s, a)]$$

的式子，即 $h(s, a)$ 不再适合作为基准函数。