

第六章 强化学习

- 下面对强化学习、监督学习和深度卷积神经网络学习的描述正确的是（ ）
 - 评估学习方式、有标注信息学习方式、端到端学习方式
 - 有标注信息学习方式、端到端学习方式、端到端学习方式
 - 评估学习方式、端到端学习方式、端到端学习方式
 - 无标注学习、有标注信息学习方式、端到端学习方式
- 在强化学习中，通过哪两个步骤的迭代，来学习得到最佳策略（ ）
 - 价值函数计算与动作-价值函数计算
 - 动态规划与 Q-Learning
 - 贪心策略优化与 Q-learning
 - 策略优化与策略评估
- 在强化学习中，哪个机制的引入使得强化学习具备了在利用与探索中寻求平衡的能力（ ）
 - ϵ 贪心策略
 - 蒙特卡洛采样
 - 动态规划
 - 贝尔曼方程
- 与马尔可夫奖励过程相比，马尔可夫决策过程引入了哪一个新的元素（ ）？
 - 反馈
 - 动作
 - 终止状态
 - 概率转移矩阵
- 在本章内容范围内，“在状态 s ，按照某个策略行动后在未来所获得回报值的期望”，这句话描述了状态 s 的（ ）；“在状态 s ，按照某个策略采取动作 a 后在未来所获得回报值的期望”，这句话描述了状态 s 的（ ）
 - 策略优化
 - 价值函数
 - 动作-价值函数
 - 采样函数

6. 将图 7.1.2 中的机器人寻路问题简化为图 1 的 2×2 的网格，假设有位于 s_1 位置的机器人拟从 s_1 这一初始位置向 s_4 这一目标位置移动。机器人每次只能向上或者向右移动一个方格，到达目标位置 s_4 则会获得奖励且游戏终止，机器人在移动过程中如果越出方格 (s_d) 则会被惩罚且被损坏、并且游戏终止。奖励值定义如下：当 $S_{t+1} = s_4$ 时奖励值为 1，当 $S_{t+1} = s_d$ 时惩罚值为 -1，其他情况下奖励值为 0。若折扣因子 $\gamma = 0.99$ ，智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上，终止状态 s_4 、 s_d 的价值函数定义为 0，试通过联立贝尔曼方程给出状态 s_1 、 s_2 、 s_3 的价值函数。




图 1 2×2 的机器人寻路问题

7. 在题 6 中，若每个状态的价值函数都初始化为 0，智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上，试优化智能体在状态 s_3 的策略。（提示：使用策略优化定理）

8. 在题 6 中，，若每个状态的价值函数都初始化为 0，智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上，试使用算法 7.2.5 中的价值迭代算法优化智能体在每个状态下的价值函数和策略，并给出迭代过程。

9. 在题 6 中, , 若图 2 表示算法的初始状态, 其中 a/b 表示对应状态的动作-价值函数的取值, 斜线左侧的 a 表示 $q_{\pi}(s, \text{上})$, 斜线右侧的 b 表示 $q_{\pi}(s, \text{右})$ 。若 $\alpha = 0.5$, 试给出算法 7.2.6 中的 Q 学习算法的一个片段的执行过程, 并给出执行完该片段后每个状态的策略。

$0.1/0$	$0/0$
$0.1/0$	$0.1/0$

图 2 Q 学习算法的初始状态

10. 采样时策略和更新时策略彼此不同的算法称为离策略算法。反之, 采样时策略和更新时策略相同的算法称为在策略算法。算法 7.2.7 给出的 Q 学习是一个离策略算法, 请给出其对应的在策略版本——Sarsa 算法。

11*. 回顾将价值函数作为 Actor-Critic 算法的基准函数的推导过程, 若将基准函数设置为 $h(s, a)$, 指出推导过程中的哪一步不再适用。