



第五章作业

1. 下面对误差反向传播 (error back propagation, BP)描述不正确的是 ()
 - a) BP 算法是一种将输出层误差反向传播给隐藏层进行参数更新的方法
 - b) BP 算法将误差从后向前传递, 获得各层单元所产生误差, 进而依据这个误差来让各层单元修正各单元参数
 - c) 对前馈神经网络而言, BP 算法可调整相邻层神经元之间的连接权重大小
 - d) 在 BP 算法中, 每个神经元单元可包含不可偏导的映射函数

D

2. 以下关于梯度下降和随机梯度下降的说明, 哪些描述是正确的?
 - a) 在梯度下降和随机梯度下降中, 为了最小化损失函数, 通常使用循环迭代的方式不断更新模型参数;
 - b) 在每次迭代中, 随机梯度下降需要计算训练集所有样本的误差和, 用于更新模型参数;
 - c) 在每次迭代中, 梯度下降使用所有数据或者部分训练数据, 用于更新模型参数.

A、C

3. 关于 sigmoid 激活函数, 下列描述正确的是?
 - a) 它是凸函数, 凸函数无法解决非凸问题;
 - b) 它可以有负值;
 - c) 它无法配合交叉熵损失函数使用;
 - d) 当输入值过大或者过小时, 梯度趋近于 0, 容易造成梯度消失问题。

D

4. 下面对前馈神经网络这种深度学习方法描述不正确的是 ()
- a) 是一种端到端学习的方法
 - b) 是一种监督学习的方法
 - c) 实现了非线性映射
 - d) 隐藏层数目大小对学习性能影响不大

D

5. 图 6.4.5 展示了长短时记忆网络的详细结构。如下描述正确的是?
- a) 如果输入 x_t 为 0 向量, 则 $h_t = h_{t-1}$
 - b) 如果 f_t 非常小或者为 0, 则误差不会被反向传播到较早的时间节点
 - c) f_t 、 i_t 和 o_t 的输出是非负数;

- d) f_t 、 i_t 和 o_t 的输出可以被看作是概率分布, 其输出为非负数且和为 1.

C

6. 关于生成对抗网络的训练, 以下说法正确的是 ()
- a) 为了加速生成对抗网络的训练, 通常采用交替训练一轮判别器和多轮生成器的方法
 - b) 当生成器能够产生足以以假乱真的数据, 即 $D(G(z))$ 的输出稳定于接近 1 的值时, 训练就完成了
 - c) 目标函数需要在训练初期提供足够的梯度, 使生成器更快开始产生能够混淆判别器的数据
 - d) 生成对抗网络在经过足够长时间的训练后可以确保收敛到全局最优

C

7. 在训练生成对抗网络时，发现损失函数的值很小，但生成器产生的数据质量并不高这可能是因为（ ）
- a) 判别器欠拟合
 - b) 判别器过拟合
 - c) 生成器欠拟合
 - d) 生成器过拟合

B

8. 请问深度学习和传统的机器学习有什么区别？

对比角度	传统机器学习	深度学习
特征提取	依赖人工设计特征	自动学习特征
模型结构	通常较浅	多层神经网络，结构较深
数据需求	小数据下也能工作	通常需要大量数据
表达能力	适合相对简单的模式	能拟合复杂非线性关系
训练成本	相对较低	计算量大
可解释性	通常较强	相对较弱，常被视为黑箱

9. (1) 请说明单层感知机为何无法模拟逻辑异或操作？
(2) 请设计一个前馈神经网络，用于拟合异或函数。

(1) 单层感知机无法模拟逻辑异或操作，是因为单层感知机只能解决线性可分问题。设单层感知机的输出为：

$$y = f(w_1x_1 + w_2x_2 + b)$$

其决策边界满足：

$$w_1x_1 + w_2x_2 + b = 0$$

在二维输入空间中，该决策边界是一条直线。对于异或函数，其真值表为：

$$(0, 0) \rightarrow 0, \quad (0, 1) \rightarrow 1, \quad (1, 0) \rightarrow 1, \quad (1, 1) \rightarrow 0$$

其中正类样本为 (0,1) 和 (1,0)，负类样本为 (0,0) 和 (1,1)。这两类样本在平面上呈交叉分布，无法用一条直线完全分开。因此，异或函数是线性不可分的，单层感知机无法模拟逻辑异或操作。

(2) 可以设计一个包含一层隐藏层的前馈神经网络来拟合异或函数。该网络包含 2 个输入神经元、2 个隐藏层神经元和 1 个输出神经元。隐藏层的两个神经元分别用于实现逻辑或和逻辑与：

$$h_1 = x_1 \vee x_2$$

$$h_2 = x_1 \wedge x_2$$

输出层再实现：

$$y = h_1 \wedge \neg h_2$$

由于逻辑异或可以表示为：

$$x_1 \oplus x_2 = (x_1 \vee x_2) \wedge \neg(x_1 \wedge x_2)$$

因此，通过隐藏层的非线性变换，可以将原本线性不可分的异或问题转化为可由输出层判别的问题。

10. 在前馈神经网络中，所有的参数能否被初始化为 0？如果不能，能否全部被初始化为其他相同的值？为什么？

在前馈神经网络中，所有参数不能全部初始化为 0，也不能全部初始化为其他相同的值。因为如果同一层神经元的参数完全相同，那么它们在前向传播中会得到相同的输出，在反向传播中也会得到相同的梯度，经过参数更新后仍然保持相同。这样会导致同一层中的多个神经元始终执行相同的计算，学习到相同的特征，无法发挥多个神经元的作用，即产生对称性问题。

若所有参数初始化为 0，则所有神经元从一开始就处于完全相同的状态，网络无法打破这种对称性，模型表达能力会严重受限。因此，前馈神经网络的参数通常不能全部取相同值，而应采用随机初始化等方法，使不同神经元具有不同的初始参数，从而学习不同的特征表示。

11. “编码器-解码器”框架被广泛用于机器翻译中，其中编码器用于对源语言进行编码，解码器用于产生目标语言。当编码器编码完毕后，会将所得信息传给解码器，同时给解码器“BOS”标签，告知解码器可以开始解码。解码器依次产生目标语言词汇，当产生“EOS”标签时解码结束。图 3 给出了通用机器翻译框架，如果目标语言的词汇量大小为 V ， y'_i 为模型预测的 V 维概率向量、

w_i 为所预测词语、 y_i 为真实值。




图 3 机器翻译中“编码-解码”框架

(1) 写出解码器的损失函数。

(2) 在模型过程中，通常会使用“微调”的方式更新预训练词向量。请写出

w_{n-1} 梯度。

(1) 解码器每一步都会输出一个 V 维概率向量：

$$y'_i = (y'_{i,1}, y'_{i,2}, \dots, y'_{i,V})$$

真实词为： y_i ，则第 i 个词的交叉熵损失为：

$$L_i = - \sum_{j=1}^V y_{i,j} \log y'_{i,j}$$

整个目标句子的损失函数为：

$$L = - \sum_{i=1}^n \sum_{j=1}^V y_{i,j} \log y'_{i,j}$$

如果把 EOS 也作为预测目标一起计算，则可以写成：

$$L = - \sum_{i=1}^{n+1} \sum_{j=1}^V y_{i,j} \log y'_{i,j}$$

其中第 $n+1$ 个预测目标为 EOS。

(2)

在微调预训练词向量时，词向量 w_{n-1} 作为解码器第 n 个时间步的输入，会影响当前隐藏状态 h_n ，进而影响输出概率向量 y'_n 。根据链式法则， w_{n-1} 的梯度可以写为：

$$\frac{\partial L}{\partial w_{n-1}} = \frac{\partial L}{\partial y'_n} \frac{\partial y'_n}{\partial h_n} \frac{\partial h_n}{\partial w_{n-1}}$$

若考虑循环神经网络中隐藏状态会继续向后传递，则 w_{n-1} 还会通过 h_n 影响后续 EOS 的预测，因此更完整地可写为：

$$\frac{\partial L}{\partial w_{n-1}} = \frac{\partial L_n}{\partial y'_n} \frac{\partial y'_n}{\partial h_n} \frac{\partial h_n}{\partial w_{n-1}} + \frac{\partial L_{EOS}}{\partial y'_{EOS}} \frac{\partial y'_{EOS}}{\partial h_{n+1}} \frac{\partial h_{n+1}}{\partial h_n} \frac{\partial h_n}{\partial w_{n-1}}$$

12.*请证明为什么 LSTM 会解决循环神经网络(RNN)中所遇到的梯度消失问题。

普通 RNN 在长序列反向传播时，梯度需要沿时间方向连续相乘。由于激活函数导数和权重矩阵的相关项往往小于 1，多次连乘后梯度会迅速趋近于 0，导致早期时刻的信息难以传递到后期，形成梯度消失问题。

LSTM 在 RNN 的基础上引入了内部记忆单元 c_t 和输入门、遗忘门、输出门。其细胞状态更新为：

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

其中 f_t 控制上一时刻记忆 c_{t-1} 保留的比例。由于 c_t 与 c_{t-1} 之间存在近似线性的加法传递路径，反向传播时：

$$\frac{\partial c_t}{\partial c_{t-1}} \approx f_t$$

当遗忘门 f_t 接近 1 时，梯度可以沿着细胞状态较稳定地向前传播，不会像普通 RNN 那样在多次非线性变换中迅速衰减。因此，LSTM 能够保留长期信息，缓解循环神经网络中的梯度消失问题。