



第四章作业

1. 请判断下面说法是否正确：线性判别分析是在最大化类间方差和类内方差的比值（ ）
- A. 正确
 - B. 错误

A

2. 在决策树建立过程中，使用一个属性对某个节点对应的数据集合进行划分后，结果具有高信息熵（high entropy），对于结果的描述，最贴切的是（ ）
- A. 纯度高
 - B. 纯度低
 - C. 有用
 - D. 无用
 - E. 以上描述都不贴切

B

3. 在一个监督学习任务中，每个数据样本有 4 个属性和一个类别标签，每种属性分别有 3、2、2 和 2 种可能的取值，类别标签有 3 种不同的取值。请问可能有多少种不同的样本？（注意，并不是在某个数据集中最多有多少种不同的样本，而是考虑所有可能的样本）（ ）
- A. 3
 - B. 6
 - C. 12
 - D. 24
 - E. 48
 - F. 72

F

4. 关于支持向量机，哪一种选择能正确填充下面的说法（ ）
支持向量机是一种__模型，其目标是__分类间隔
- A. 生成，最大化
 - B. 生成，最小化
 - C. 判别，最大化
 - B. 判别，最小化

C

5. 以下哪种方法不属于监督学习方法（ ）
- A. 聚类
 - B. 决策树
 - C. 线性回归
 - D. 朴素贝叶斯

- 
- E. 支持向量机
 - F. 以上都不属于监督学习方法

A

6. 在 Adaboosting 的迭代中, 从第 t 轮到第 $t+1$ 轮, 某个被错误分类样本的惩罚被增加了, 可能因为该样本 ()
- A. 被第 t 轮训练的弱分类器错误分类
 - B. 被第 t 轮后的集成分类器 (强分类器) 错误分类
 - C. 被到第 t 轮为止训练的大多数弱分类器错误分类
 - D. B 和 C 都正确
 - E. A, B 和 C 都正确

A

7. 可以从最小化每个类簇的方差这一视角来解释 K 均值聚类的结果, 下面对这
- 一视角描述不正确的是 ()
- a) 最终聚类结果中每个聚类集合中所包含数据呈现出来差异性最小
 - b) 每个样本数据分别归属于与其距离最近的聚类质心所在聚类集合
 - c) 每个簇类的方差累加起来最小
 - d) 每个簇类的质心累加起来最小

D

8. 下面对相关性(correlation)和独立性(independence)描述不正确的是 ()
- a) 如果两维变量线性不相关, 则皮尔逊相关系数等于 0
 - b) 如果两维变量彼此独立, 则皮尔逊相关系数等于 0
 - c) “不相关”是一个比“独立”要强的概念, 即不相关一定相互独立
 - d) 独立指两个变量彼此之间不相互影响

C

9. 下面对主成分分析的描述不正确的是 ()
- a) 主成分分析是一种特征降维方法
 - b) 主成分分析可保证原始高维样本数据被投影映射后, 其方差保持最大
 - c) 在主成分分析中, 将数据向方差最大方向进行投影, 可使得数据所蕴含信息没有丢失, 以便在后续处理过程中各个数据“彰显个性”
 - d) 在主成分分析中, 所得低维数据中每一维度之间具有极大相关度

D

10. 下面对特征人脸算法描述不正确的是 ()
- a) 特征人脸方法是一种应用主成分分析来实现人脸图像降维的方法
 - b) 特征人脸方法是用一种称为“特征人脸(eigenface)”的特征向量按照线性组合

形式来表达每一张原始人脸图像

- c) 每一个特征人脸的维数与原始人脸图像的维数一样大
- d) 特征人脸之间的相关度要尽可能大

D

11. 在潜在语义分析中, 给定 M 个单词和 N 个文档所构成的单词-文档矩阵 (term-document) 矩阵, 对其进行分解, 将单词或文档映射到一个 R 维的隐性空间。下面描述不正确的是 ()
- a) 单词和文档映射到隐性空间后具有相同的维度
 - b) 通过矩阵分解可重建原始单词-文档矩阵, 所得到的重建矩阵结果比原始单词-文档矩阵更好捕获了单词-单词、单词-文档、文档-文档之间的隐性关系
 - c) 这一映射过程中需要利用文档的类别信息
 - d) 隐性空间维度的大小由分解过程中所得对角矩阵中对角线上不为零的系数个数所决定

C

12. 假设有两批从同样的真实数据分布中采样得到去完成同一任务的数据集 A 和 B。A 包含 100K 数据，B 包含 10K 数据。按照 9:1 这一同样比例随机将 A 和 B 分别划分为训练集和测试集。图 1 给出了数据集 A 和数据集 B 随着模型复杂度增加所对应训练误差(A,Train 以及 B,Train)和测试误差(A,Test 以及 B,Test)的曲线图。请指出哪个图正确表示了随着模型复杂度增加所对应训练误差和测试误差的变化曲线图。




图 1 数据集 A 和数据集 B 随模型复杂度增加所对应的训练误差和测试误差变化示意图

A

- 训练误差随模型复杂度增加而下降
- 测试误差随模型复杂度增加一般先下降后上升
- 数据量越大，训练误差通常更高，测试误差通常更低

13. 加入 L_2 标准化 (normalization) 后，对于包含参数 w 的线性回归损失函数的标准形式为：

$$L = (Y - Xw)^T(Y - Xw) + \lambda w^T w \quad \text{其中 } \lambda > 0$$

- (1) 假设 L_2 标准化项被误写为 $\lambda Y^T Y$ ，请解释为什么该项起不到标准化的作用。
- (2) 在上述 L_2 标准化中，如果 λ 小于 0，请解释为什么起不到标准化的作用。

(1) L_2 正则化的作用是通过 $\lambda w^T w$ 惩罚模型参数 w 的大小，从而限制模型复杂度。如果误写成 $\lambda Y^T Y$ ，由于 Y 是训练集标签，是固定常量，与待优化参数 w 无关，因此该项对 w 的梯度为 0。在最小化损失函数时，它只相当于给目标函数加上一个常数，不会改变最优参数 w ，所以起不到正则化作用。

(2) 在 L_2 正则化中要求 $\lambda > 0$ ，此时参数越大， $\lambda w^T w$ 越大，模型会受到更强惩罚，从而抑制过拟合。如果 $\lambda < 0$ ，则参数越大， $\lambda w^T w$ 反而越小，损失函数会倾向于通过增大参数来降低目标值。这不仅不能限制模型复杂度，反而可能使参数无限增大，因此起不到正则化作用。

14. 考虑下面一个数据集：

序号	出去玩	天气状况	有同伴	零花钱	特殊节日	心情指数 (1 差-5 好)
1	是	好	无	多	是	5
2	是	一般	有	多	是	5
3	是	一般	有	少	否	1
4	是	一般	有	少	否	3
5	是	一般	有	少	否	5
6	是	好	无	多	是	5

7	是	好	无	多	是	5
8	否	一般	无	多	是	1
9	否	一般	有	少	否	1
10	否	一般	无	少	否	5

对于如上数据，考虑使用 Ada boosting 方法来训练“是否出去玩”强分类器。每个弱分类器可考虑对单个属性的分类，比如对于“心情指数”这一属性，可考虑心情指数 > 2 和心情指数 < 4 两个方面。请问答下列问题：

- (1) Ada boosting 在第一轮迭代中将会选择哪一个弱分类器？
- (2) 第一轮迭代前与迭代后每个样本的权重是多少？
- (3) 第二轮迭代选择的弱分类器是哪一个？分类器权重是多少？
- (4) 写出三轮迭代后的强分类器的表达式（每个弱分类器可用字母替代）

(1)

选择 h_1 ：心情指数 $> 2 \Rightarrow$ 出去玩，否则不出去玩

该分类器错分样本 3 和 10，错误率： $\varepsilon_1 = 0.2$

分类器权重： $\alpha_1 = \frac{1}{2} \ln \frac{1-0.2}{0.2} = \frac{1}{2} \ln 4 \approx 0.693$

(2)

迭代前：

序号	权重
1-10	0.1

迭代后：

序号	权重
1	0.0625
2	0.0625
3	0.25
4	0.0625
5	0.0625
6	0.0625
7	0.0625
8	0.0625
9	0.0625
10	0.25

(3)

选择 h_2 ：有同伴 $\Rightarrow$ 出去玩，否则不出去玩

加权错误率： $\varepsilon_2 = 0.25$

分类器权重： $\alpha_2 = \frac{1}{2} \ln 3 \approx 0.549$

(4)

取第三轮：

h_3 ：特殊节日=是 $\Rightarrow$ 出去玩，否则不出去玩

其错误率： $\varepsilon_3 = \frac{7}{24}$

分类器权重： $\alpha_3 = \frac{1}{2} \ln \frac{17}{7} \approx 0.444$

所以： $H(x) = \text{sign}(0.693h_1(x) + 0.549h_2(x) + 0.444h_3(x))$

* 15. 线性判别分析模型由如下的假设所定义：

$$P(x|y=k) = \frac{e^{\frac{1}{2}(x-\mu_k)^T \Sigma^{-1}(x-\mu_k)}}{\sqrt{2\pi} |\Sigma|^{\frac{1}{2}}}$$

其决策边界由如下的对数几率比值确定：

$$\log \frac{P(y=1|x)}{P(y=0|x)} = \log \frac{P(x|y=1)P(y=1)}{P(x|y=0)P(y=0)}$$

请简要证明线性判别分析的决策边界是线性的。

LDA 假设各类别条件分布均为高斯分布，且不同类别共享相同协方差矩阵 Σ 。二分类时，决策边界由 $\log \frac{P(y=1|x)}{P(y=0|x)} = 0$ 决定。

由贝叶斯公式可得 $\log \frac{P(y=1|x)}{P(y=0|x)} = \log \frac{P(x|y=1)P(y=1)}{P(x|y=0)P(y=0)}$

将高斯密度代入后，由于两个类别具有相同协方差矩阵，展开二次型时 $x^T \Sigma^{-1} x$ 项相互抵消，最后只剩下关于 x 的一次项和常数项，即 $\log \frac{P(y=1|x)}{P(y=0|x)} = w^T x + b$

因此决策边界为

$$w^T x + b = 0$$

是线性的。

16. 说明在 k-means 算法执行的过程中，其目标函数 $\sum_{i=1}^K \sum_{x \in G_i} \|x - c_i\|^2$ 是严格递减的，并解释为什么 k-means 算法可以确保在有限步内收敛。

k-means 的目标函数为

$$J = \sum_{i=1}^K \sum_{x \in G_i} \|x - c_i\|^2$$

其迭代过程包括两个步骤。第一步，在质心固定的情况下，将每个样本分配到距离最近的质心所在的簇中。由于每个样本都选择使 $\|x - c_i\|^2$ 最小的簇，因此该步骤不会使目标函数增大。第二步，在样本划分固定的情况下，重新计算每个簇的质心。对于固定簇 G_i ，使

$$\sum_{x \in G_i} \|x - c_i\|^2$$

最小的 c_i 是该簇内所有样本的均值，因此更新质心也不会使目标函数增大。

因此，k-means 每一轮迭代都会使目标函数单调不增；若聚类划分或质心发生有效变化，则目标函数严格递减。由于样本数有限，每个样本只能被分到有限个簇中，所以可能的聚类划分数有限。目标函数又在有效迭代中严格下降，因此算法不可能无限循环，最终会在有限步内达到稳定状态，即收敛。

18. EM 算法和 k-均值聚类算法有着非常相似的迭代结构，可以说 k-均值聚类算法是 EM 算法的一种特殊实现。如果将 k-均值聚类中的聚类质心作为隐变量，试从 EM 算法角度来解释 k-均值聚类算法，即描述 k-均值聚类算法的 E 步骤和 M 步骤。

从 EM 算法角度看, k-means 中每个样本所属的簇可以看作隐变量, 聚类质心可以看作待估计参数。设样本 x_i 的隐变量为 z_i , 表示其所属簇编号; 当前质心为

$c_1, c_2, \dots, c_K$ 。

在 E 步中, 固定当前质心, 对每个样本估计其所属簇。k-means 采用硬分配方式, 将样本 x_i 分配给距离最近的质心:

$$z_i = \arg \min_k \|x_i - c_k\|^2$$

即确定每个样本属于哪个簇。

在 M 步中, 固定样本的簇分配, 重新估计每个簇的质心。对于第 k 个簇 G_k , 新的质心为该簇内所有样本的均值:

$$c_k = \frac{1}{|G_k|} \sum_{x_i \in G_k} x_i$$

该质心使簇内平方误差 $\sum_{x_i \in G_k} \|x_i - c_k\|^2$ 最小。

因此, k-means 可以看作 EM 算法的一种特殊实现: E 步进行样本到簇的硬分配, M 步更新簇的质心。与一般 EM 的软分配不同, k-means 对每个样本只给出一个确定的簇归属。

19. 在机器学习中, 总体是特定研究任务中所定义的全部个体集合, 样本是从总体中选择出来的个体子集。一般使用从包含有限个体数目的样本中所得到的信息来作出描述总体的一般结论。样本方差 (sample variance) 和总体方差是两个不一样的概念。使用样本均值来估计总体均值是无偏的 (unbiased), 但使用样本方差 s^2 来估计总体方差 σ^2 却是有偏的 (biased)。总体方差 $\sigma^2 = E[(x - \mu)^2]$, 其中 x 为来自总体的一个样本, μ 是总体均值。假设样本集合 x 包含了 n 个数据 $\{x_1, x_2, x_3, \dots, x_n\}$, 在了解下面样本均值是总体均值的无偏估计以及 $E\left[\frac{1}{n} \sum_{i=1}^n (\bar{x} - x_i)^2\right] = \frac{n-1}{n} \sigma^2$ 的基础上, 证明如果样本方差定义为 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$, 则 $E(s^2) = \sigma^2$ 。

a) 样本均值是对总体均值无偏估计的证明过程

设样本 $x_1, x_2, \dots, x_n$ 独立同分布地来自总体, 且总体均值为 μ , 总体方差为 σ^2 。样本均值为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

因为 $E(x_i) = \mu$, 所以

$$E(\bar{x}) = E\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n} \sum_{i=1}^n E(x_i) = \frac{1}{n} \cdot n\mu = \mu$$

因此样本均值是总体均值的无偏估计。

又由题设已知

$$E \left[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right] = \frac{n-1}{n} \sigma^2$$

两边同时乘以 n ，得

$$E \left[\sum_{i=1}^n (x_i - \bar{x})^2 \right] = (n-1) \sigma^2$$

若定义样本方差为

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

则

$$E(s^2) = E \left[\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \right] = \frac{1}{n-1} (n-1) \sigma^2 = \sigma^2$$

因此，按上述方式定义的样本方差是总体方差的无偏估计。