

2026年全国大学生计算机系统能力大赛 智能计算创新设计赛（先导杯）

基于国产加速卡的Qwen大模型推理服务优化 赛题技术方案

一、赛题总体介绍

第1条 随着大语言模型进入工程部署落地阶段，推理服务性能已成为影响部署成本、服务稳定性和用户体验的关键因素。尤其在长上下文与混合长度场景下，随着输入序列长度的增加，单请求的资源需求急剧上升。KV Cache 占用随上下文长度线性膨胀，HBM 带宽压力与显存碎片问题突出，容易导致首 token 时延（TTFT）上升、输出吞吐下降。当前统一的 vLLM 推理框架具备基础的处理能力，但在长上下文单请求负载下，默认机制仍难以充分挖掘国产加速卡（本赛题采用 DCU）的计算与带宽潜力，兼顾吞吐、时延与显存占用。

第3条 本赛题的性能优化聚焦于不同输入长度的单请求在线推理服务。参赛者需结合 Qwen3.5-72B 模型特点、长上下文输入特征和 DCU 硬件特性，采取针对性优化策略，包括但不限于：KV Cache 与显存管理优化、执行路径与算子优化，以及在允许边界内的精度无损压缩方案。

第2条 参赛者需在统一模型权重、统一容器镜像、统一 vLLM 0.18.1 推理框架和统一服务接口条件下开展评测。优化方案的核心目标是：在 TTFT P99 和 TPOT P99 均满足规定 SLA 门限的约束前提下，最大化输出吞吐量，并改善显存使用效率与服务稳定性。SLA 为硬性约束，违反则该档位吞吐量得分直接清零。

第4条 镜像预装内容固定为 Python 3.10.12、指定版本 PyTorch 2.10.0、vLLM 0.18.1、固定版本 transformers 5.5.0、Qwen3.5-72B 官方 tokenizer、官方 chat template 和官方 bf16 原始权重以及官方基准测试工具。选手可叠加自定义层，包括安装 Python 包、编译 custom kernel，但需提交改动说明。最终评测仅在统一容器环境内执行，宿主机不注入任何额外库，评测期间禁止从外

部网络下载任何依赖。

二、初赛要求与评分标准

第5条 本赛题初赛聚焦真实场景下的在线推理服务效率优化，主要挑战维度如下：

1. KV Cache 与显存管理优化

高效块管理与碎片化控制：设计更高效的 PagedAttention 块分配与回收机制，针对长上下文请求优化块粒度与对齐策略，降低单请求内的显存碎片率与 HBM 访问开销。

2. 框架与算子优化

(1) Decode 阶段算子优化：针对生成阶段的 Attention 算子、Linear 算子，结合 DCU 的显存带宽与计算特性，进行算子融合与内核优化，降低每 Token 生成耗时（TPOT）。

(2) 执行路径优化：减少 Python 层调度开销、降低 kernel launch 延迟，优化调度逻辑与内存拷贝路径，缩短首 Token 时延（TTFT）。

第6条 本赛题初赛建议的优化内容包括：

1. Decode 阶段调度进行深度定制。
2. 允许对 KV Cache 的分配机制、显存预算控制和块管理策略进行优化。
3. 允许结合 DCU 的显存容量、带宽、片上缓存层级、并行执行特征和数据搬运开销，对资源组织调度方式进行适配优化。

第7条 本赛题初赛禁止的行为包括：

1. 不得通过修改采样参数（如强行调低 Max Tokens）、截断输入、跳过长样本、过滤困难样本、不得跳过层等方式规避真实推理开销。
 2. 不得通过预缓存测试集与答案、预生成中间结果等针对性优化手段响应请求。
 3. 不得绕开统一服务接口、评测流程与资源统计路径，不得引入题目规定外的辅助模型（如外挂自行训练的小模型用于投机采样等）。
- (1) 严禁修改模型结构，替换模型权重、改变模型推理语义或输出口径。不得通过后训练、蒸馏、微调等方式修改模型。
- (2) 量化操作边界：禁止在权重加载前、权重加载后、服务初始化阶段或正式推理前，对模型权重进行持久化量化、结构化剪枝、权重重排压缩、模型图重构、模型格式转换或生成可复用量化权重缓存。（允许推理过程中的非持

久化、算子级低精度计算优化，例如激活值动态量化、KV Cache 量化、kernel 内部临时类型转换、低精度矩阵乘法、Attention 内核优化等。)

(3) 模型剪枝边界：禁止任何形式的结构化剪枝、非结构化剪枝、动态通道跳过、动态层跳过、注意力头裁剪、token pruning、early-exit 等改变模型有效计算结构或输出语义的行为。

(4) 推理过程中不得生成可供后续样本复用的新模型文件、量化权重文件、剪枝权重文件或压缩权重缓存。

第8条 初赛主要扣分与失效点如下：

1. SLA 熔断：吞吐提升明显，但 TTFT、TPOT（每个输出 Token 的平均耗时）的 P99 时延严重超标，或服务完成率下降超过 1%，该档位吞吐得分将直接清零。
2. 方案与显存、带宽、访存等物理约束脱节，或纯粹针对特定评测数据集写死的 If-Else 过拟合规则。

第9条 初赛评价指标（总分 100 分）如下：

1. 初赛评估参赛方案在指定国产加速卡（DCU）单卡环境下的实际服务能力。评测数据集由 LongBench 和 RULER 子集混合重组，**初赛题并发数固定为 1**。
2. 按输入长度划分为三个区间：4k - 8k、8k - 16k、16k - 32k。任务类别参考现有长文本评测集的任务形态：问答和摘要参考 LongBench 的文档 QA 与摘要任务；检索和聚合参考 RULER 的增强检索任务与信息聚合任务。请求分布特征参考如下：

任务类别	数据集选择	任务范围	评分指标
问答	LongBench	单文档 QA、多文档 QA	Exact Match
摘要	LongBench	单文档长文摘要、多文档摘要	ROUGE-L
检索	RULER	单点检索、多点检索	Accuracy
聚合	RULER	关键词聚合、数值统计	Accuracy

3. 评测相关指标定义

为避免统计口径争议，评测时所有核心指标遵循以下严格定义：

- (1) 性能评测：统一使用 vllm bench serve 完成，用于对参赛者部署的推理服务进行压测，并统计服务性能相关指标，包括输出吞吐量（Throughput）、

首 Token 时延 (TTFT)、TPOT。

(2) 精度评测：统一使用 OpenCompass 完成，用于对问答、摘要、检索、聚合等任务的输出结果进行精度评估。精度评测结果用于精度扣分计算，不参与吞吐量或时延指标统计。

(3) 吞吐量 (Throughput)：严格定义为输出吞吐量 (Output Tokens / Second)。计算逻辑为：所有完成请求的生成 Token 总数 / (最后一个请求完成的时间点 - 第一个请求发出的时间点)。输入的 Prompt Token 不计入吞吐量分子。

(4) TTFT (Time To First Token, 首 Token 时延)：采用客户端端到端计时。

- 起算点：评测客户端向推理服务 API 发出 HTTP 请求的绝对时间戳。
- 终止点：评测客户端收到流式返回第一个生成 Token 的绝对时间戳。
- 包含内容：TTFT 明确包含 Tokenizer 编码时间以及首 Token 的 Prefill 计算时间。**初赛题并发数固定为 1**，引擎内无排队等待时间。

(5) TPOT (Time Per Output Token, 每 Token 生成耗时)：对每条请求，定义为从收到第一个 Token 到收到最后一个 Token 的时间差，除以 (输出 Token 数 - 1)。将全部请求的 TPOT 值汇入全局池后取 P99 分位值 (TPOT P99)。输出 Token 数为 1 的请求不参与 TPOT 统计。

(6) P99 统计维度：

- TTFT P99：按请求维度统计，取全部请求首字时延的 P99 分位值，各档位分别计算，各档独立判断是否达标。
- TPOT P99：所有请求的 TPOT 值汇总后取 P99 分位值，全局统一（不分档），适用于所有档位的 SLA 判断。

(7) 官方 Baseline 核心参数示例（评测时严格锁定）：`vllm serve Qwen/Qwen3.5-27B --max-model-len 32768`。以下参数严格锁定：`max_tokens`、`temperature=0`、`max-num-seqs`。

(8) 不允许调整的参数（所有影响任务定义、上下文范围和输出行为的参数严格锁定）。以下按类别列出不可调整项；若与本说明存在差异，以评测脚本与实际评测命令的锁定为准。

- 模型与分词：模型权重 (`model`)、`tokenizer`、`tokenizer-mode`、`chat template`。
- 上下文与批处理：`--max-model-len`、`--max-num-seqs`、`--max-num-batched-`

tokens 及其它 batch scheduler 相关参数（包括不允许 vLLM 内部 batch scheduler 相关代码修改）。

- 禁止能力：任何形式的投机解码，包括但不限于 draft model、MTP、多头预测、外挂小模型、自训练预测器、基于中间层的 early-exit draft、预生成 token 序列缓存等。参赛方案必须基于官方模型的标准自回归解码流程完成输出生成。
- Bench 与结果：bench 的 percentile/percentiles 统计口径、结果保存选项、结果解析脚本。
- 服务接口：--served-model-name、OpenAI API 路径、请求/响应格式（host/port/路由由平台固定）。

4. 输出吞吐量（总计 100 分）

吞吐量评分基于统一的、提前评测验证的官方基准线（Baseline）计算相对提升，杜绝调参套利。

在 SLA 门限通过的前提下，按三档输入长度分别计算吞吐提升得分，三档权重分别为 20%、50%、30%，各档满分分别为 20 分、50 分、30 分，合计 100 分。

单档相对提升率 = (参赛方案该档吞吐量 - Baseline该档吞吐量)/Baseline该档吞吐量

$$\text{各档得分} = \text{该档满分} \times (60\% + 40\% \times (1 - e^{-1.3 \times \text{单档相对提升率}}))$$

5. 时延 SLA 熔断机制（硬性约束，不另计分值）

服务可用性通过首 Token 时延（TTFT）和每 Token 生成耗时（TPOT）联合评估，仅作为硬性约束，不另计得分。

SLA 门限：

- TTFT P99（各档分别） $\leq$ Baseline TTFT P99（对应档） $\times 1.5$
- TPOT P99（全局） $\leq$ Baseline TPOT P99（全局） $\times 1.5$

熔断机制：各不同上下文长度档位的吞吐测试中，一旦上述任一 SLA 指标未能达标，该档位对应的吞吐量得分直接清零。

6. 约束条件：模型精度

初赛精度评估与吞吐评测使用同一套任务类型与评分口径，统一要求如下：

- 评测时 Temperature = 0.0；
- 所有任务均与官方 Baseline 输出结果或标准答案进行对比；

对四类任务分别计算精度结果，并统计相对 Baseline 的性能下降幅度，记为 Δ ，根

据下表得到各任务对应精度系数 k_i ，取四类任务系数均值作为最终精度系数。

精度下降幅度 Δ	精度系数 k
$\Delta \leq 1.0\%$	1.00
$1.0\% < \Delta \leq 2.0\%$	0.97
$2.0\% < \Delta \leq 3.0\%$	0.94
$3.0\% < \Delta \leq 5.0\%$	0.90
$5.0\% < \Delta \leq 10.0\%$	0.85
$\Delta > 10\%$	0（该类任务不计分）

$$\Delta = (\text{Baseline精度} - \text{参赛方案精度}) / \text{Baseline精度} \times 100\%$$
$$\text{最终得分} = \text{吞吐量得分} \times \frac{1}{4} \times \sum_{i=1}^4 k_i$$

三、决赛要求与评分标准

第 10 条 决赛形式为线下比赛和答辩，决赛各环节的要求、安排和评分标准在决赛阶段另行公布。

四、软硬件系统规范

第11条 参赛者在进行模型优化和部署时，需使用以下工具和环境：

1. 硬件环境： 初赛使用指定国产 x86 处理器及 DCU 加速卡（单卡评测环境）；决赛采用同型号多卡分布式评测环境，具体卡数由组委会赛前统一公示。
2. 软件环境： Python 3.10.12、固定版本 PyTorch 2.10.0、vLLM 0.18.1、transformers 5.5.0、Qwen3.5-27B（bf16） 官方原始权重。
3. 盲测公平性： 统一使用测试集和请求流。评测为黑盒盲测，参赛者无法提前获知完整的样本内容和请求先后顺序，杜绝针对特定 Prompt 的缓存作弊。发现任何伪造结果、隐藏异常等违背技术道德的行为，立刻取消成绩。

五、参赛作品提交要求

第12条 源码提交与编译要求：

1. 完整源代码： 包含所有源代码和编译脚本，代码规范，确保在指定环境中能够顺利运行。代码需具有良好的注释和清晰的结构，便于评审人员理解和复

现。

2. 参赛队伍应在测评机器上完成源码编译，并保证编译成功。评测平台将在统一容器环境下执行编译，若编译失败，平台将输出编译错误日志（log）并返回给参赛队伍，队伍需在规定时间内修复后重新提交。

第13条 环境变量说明文档

若参赛方案依赖自定义环境变量，需随代码一并提交环境变量说明文档，文档须包含以下内容：

1. 配置了哪些环境变量（逐项列出变量名与取值）。
2. 每个环境变量的作用及配置原因。
3. 未提交说明文档但实际使用了自定义环境变量的方案，视为提交不完整，评测结果可能无效。

第14条 优化方案说明文档

参赛队伍须提交优化方案说明文档，需清晰描述：

1. 所采用的优化方法与技术路线。
2. 各项优化措施对性能提升的贡献分析。
3. 优化点汇总表

文档格式不限，建议含关键代码路径说明及对应的性能对比数据。

第15条 所有优化需支持在组委会平台正确运行。参赛队伍必须严守学术诚信。若使用第三方知识产权、开源代码、公开算法或第三方库，以及引用他人源码等，必须在提交的说明文档及源码项目README.md文件头部进行明确标注与说明。

六、比赛网站与参考资源

第16条 比赛网站：<https://pra.xtnl.org.cn/>。

第17条 比赛网站提供多种软件开发工具及设计资料，包括但不限于以下内容：HIP 程序设计语言规范及说明、DTK软件使用说明、竞赛平台（代码提交方式、代码提交示例、竞赛平台使用）说明文档、硬件资源调试和使用指南等。

七、其他

第18条 本技术方案的最终解释权归2026年全国大学生计算机系统能力大赛智能计算设计赛（先导杯）技术委员会。